

Univ.-Prof. Dr. Ulrike Baumöl
Dipl.-Ök. Sarah Hackstein

32711

Business Intelligence

Einheit 3
Intelligente Datenhaltung und -bereitstellung

Fakultät für
**Wirtschafts-
wissenschaft**

Übersicht zum Modul 32711

Business Intelligence

Einheit 1: Grundlagen der Business Intelligence

Einheit 2: Methoden und Instrumente der Business Intelligence

Einheit 3: Intelligente Datenhaltung und -bereitstellung

Einheit 4: Neue Entwicklungen und Anwendungsbeispiele der Business Intelligence

Das Werk ist urheberrechtlich geschützt. Die dadurch begründeten Rechte, insbesondere das Recht der Vervielfältigung und Verbreitung sowie der Übersetzung und des Nachdrucks, verbleiben bei der FernUniversität. Das Werk darf gemäß § 53 UrhG im privaten Rahmen zum Beispiel durch Kopien oder digitale Speicherung vervielfältigt werden.

Inhaltsverzeichnis

Abbildungsverzeichnis	II
Tabellenverzeichnis.....	III
Abkürzungsverzeichnis	IV
1 Einführung.....	1
1.1 Inhalte der Einheit 3 „Intelligente Datenhaltung und Datenbereitstellung“	2
1.2 Lernziele der Einheit „Intelligente Datenhaltung und Datenbereitstellung“	3
2 Grundlegende Begriffe und Konzepte	4
2.1 Business Rules	4
2.2 Metadatenmanagement	9
2.3 Datenqualitätsmanagement	13
2.3.1 Qualitätskriterien	14
2.3.2 Qualitätssicherungsstrategien	16
2.3.3 Vorbeugung vor neuen Datenqualitätsproblemen.....	18
3 Data Warehouse-Systeme	20
3.1 Gesamtarchitektur eines Data Warehouse-Systems.....	21
3.2 Definition und Ziele eines Data Warehouse.....	22
3.3 Komponenten eines DWH-Systems.....	24
3.4 Data Marts	29
4 Online Analytical Processing (OLAP).....	33
4.1 Anforderungen	34
4.2 Ausprägungen	37
4.3 Operationen in OLAP.....	39
4.4 Zusammenfassung der Operationen in OLAP	43
5 Zusammenfassung	45
Literaturverzeichnis.....	47

Abbildungsverzeichnis

Abb. 1: Ausschnitt aus dem Business Motivation Model	5
Abb. 2: Prozesse des Metadatenmanagements	12
Abb. 3: Datenqualitätskriterien	14
Abb. 4: Prozess des Datenqualitätsmanagement	16
Abb. 5: Total Quality Management-Konzept nach English	17
Abb. 6: Einbettung von Data Warehouses in den Gesamtkontext der BI	20
Abb. 7: Zusammenfassende Gesamtarchitektur	21
Abb. 8: Dimensionen von operativen und dispositiven Daten	23
Abb. 9: Der ETL-Prozess	26
Abb. 10: Der OLAP-Würfel	33
Abb. 11: Rechenschiebermodell	34
Abb. 12: Beispielhaftes Star-Schema	38
Abb. 13: Die OLAP-Operation Pivottisierung/Rotation	39
Abb. 14: Pivottabelle	40
Abb. 15: Die OLAP-Operationen Roll-Up und Drill-Down	41
Abb. 16: Die OLAP-Operation Slice	42
Abb. 17: Die OLAP-Operation Dice	42
Abb. 18: OLAP-Würfel	43
Abb. 19: OLAP-Operation: Roll-Up	43
Abb. 20: OLAP-Operation: Drill-Down	44
Abb. 21: OLAP-Operation: Slicing	44
Abb. 22: OLAP-Operation: Dicing	45
Abb. 23: OLAP-Operation: Rotation (Pivotierung)	45

Tabellenverzeichnis

Tab. 1: Eigenschaften von Data Marts und Data Warehouses	31
--	----

Abkürzungsverzeichnis

BI.....	Business Intelligence
BMM	Business Motivation Model
BRML.....	Business Rule Markup Language
CRM.....	Customer Relationship Management
DBMS	Datenbankmanagementsystem
DWH	Data Warehouse
EPK.....	Ereignisgesteuerte Prozessketten
ERP	Enterprise Resource Planing
ETL	Extraktion – Transformation – Laden
HOLAP.....	Hybrid Online Analytical Processing
KDD.....	Knowledge Discovery in Databases
MOLAP.....	Multidimensional Online Analytical Processing
ODS.....	Operational Data Store
OLAP	Online Analytical Processing
OLTP.....	Online Transactional Processing
ROLAP	Relational Online Analytical Processing
RuleML.....	Rule Markup Language

1 Einführung

Für eine gezielte Entscheidungsunterstützung ist es enorm wichtig, dass die Daten, die die benötigten Informationen für Entscheidungen liefern sollen, effizient zur Verfügung gestellt werden. Hierzu wird von vielen Unternehmen ein Data Warehouse genutzt.

Ein Data Warehouse (DWH) ist eine für Analysezwecke optimierte zentrale Datenbank, die Daten aus mehreren, in der Regel heterogenen Quellen zusammenführt.¹

So setzt beispielsweise die öffentliche Verwaltung ein DWH ein, um Daten gezielt für die Balanced Scorecard bereitstellen zu können. Denn die Balanced Scorecard hat nur dann einen hohen Informationsgehalt, wenn die richtigen Daten richtig miteinander kombiniert werden, um so problembezogene Kennzahlen generieren zu können. Hierzu sind Daten aus verschiedenen Abteilungen wie der Personalabteilung, des Marketings oder des Controllings erforderlich, wodurch sich einige Probleme ergeben. So werden beispielsweise Daten redundant gehalten und gepflegt, was insgesamt zu einer ineffizienten Datenhaltung führt. Diese Probleme werden durch die Verwendung eines DWH vermieden (Stein, 2001).

Ein weiteres Anwendungsfeld von DWHs bildet die Pharmaindustrie. Besonderes Charakteristikum dieser Branche ist, dass hier viele verschiedene Datenquellen zur Generierung von Informationen genutzt werden können. So sammelt jedes Pharmaunternehmen zum einen intern eigene Daten z. B. durch Marktforschung oder Kundendaten. Jedoch werden auch vielfach externe Datenquellen hinzugezogen. So werden beispielsweise in einer Datenbank alle Einkäufe von Human-Arzneimitteln der Bundesrepublik Deutschland gespeichert. Eine weitere Datenbank beinhaltet alle Daten zu Rezeptverordnungen der gesetzlichen Krankenkassen. Wenn Pharmaunternehmen z. B. gezielt Marketingaktion durchführen wollen, so müssen Daten aus verschiedenen Datenquellen in verschiedenen Datenformaten zusammengefügt werden. Um dies zu vereinfachen, können die Unternehmen ein DWH einsetzen (Holthuis, Data-Warehousing im Pharma-Marketing, 2001).

Auch im Bereich der Versicherungswirtschaft werden DWHs vielfach eingesetzt. Eine Umfrage der META Group, an der mehr als 500 Versicherungsunternehmen teilnahmen, hat die Hauptgründe für den Einsatz von DWHs bei deutschen Versicherungen herausgestellt. Demnach gaben 23% der Befragten an, dass ein DWH bei dem Erkennen von Entscheidungserfordernissen und Trends helfen kann. Für 20% der Befragten kann mit dem Einsatz eines DWH eine qualitativ bessere Entscheidung getroffen werden. Immerhin 19% der Befragten gaben an, durch ein DWH die vorhandenen Daten und Systeme effizienter nutzen zu können (Becker & Proff, 2001).

Die Beispiele haben gezeigt, dass DWHs in unterschiedlichsten Branchen eingesetzt werden. Und auch das Anwendungsspektrum umfasst nicht nur die Informationsbereitstellung, sondern beispielsweise auch flexible und komplexe Datenanalysen. Letztlich ist das Ziel die empfängerge-

¹ <http://www.enzyklopaedie-der-wirtschaftsinformatik.de/lexikon/daten-wissen/Business-Intelligence/Data-Warehouse/index.html/?searchterm=Data%20warehouse>

rechte Bereitstellung von Informationen, die der Unterstützung von Entscheidungen dienen (Navrade, 2008). Hierzu gibt es in einem DWH-System Analysekomponenten, die dies gezielt unterstützen können. Eine wesentliche Komponente ist dabei das Online Analytical Processing (OLAP). OLAP wird von Entscheidern genutzt, um Daten gezielt und strukturiert für eine Entscheidung bereitzustellen.

1.1 Inhalte der Einheit 3 „Intelligente Datenhaltung und Datenbereitstellung“

Die vorliegende Einheit setzt sich mit der Datenhaltung auseinander, die die wesentliche Basis für Wissensgenerierung im Rahmen des Knowledge Discovery in Databases (KDD)-Prozesses (Einheit 2).

Business Rules sind Regeln, die beispielsweise Prozesse steuern. Diese Regeln sollen dabei helfen, das Alltagsgeschäft eines Unternehmens effizient zu gestalten. Insbesondere im Bereich von DWHs nehmen Business Rules einen hohen Stellenwert ein. So müssen Regeln existieren, die Vorgaben über die Prozesse der Datenhaltung und -bereitstellung machen.

Zur intelligenten Datenhaltung und -bereitstellung gehört auch, dass die Metadaten eines Unternehmens effizient gesammelt, gespeichert und der Zugriff darauf ermöglicht wird. Um dies zu erreichen, sollte ein Unternehmen ein funktionierendes Metadatenmanagement institutionalisieren. Die Metadaten sind für den Erfolg und den Aufbau eines DWH-Systems maßgeblich.

Der Aufbau eines DWH-Systems bildet den Schwerpunkt in Kapitel 3. Nach einer grundlegenden Definition von DWH werden die einzelnen Komponenten eines DWH-Systems erläutert und als Gesamtarchitektur dargestellt. Für DWH existieren jedoch unterschiedliche Ausgestaltungsformen. So werden zentrale DWHs, Data Marts und virtuelle DWHs unterschieden. Jedes Unternehmen muss dabei für sich entscheiden, welche Ausgestaltungsform sich für ihr Unternehmen am besten eignet. Dazu werden die Ausgestaltungsformen dargestellt sowie die Vor- und Nachteile erläutert. Wenn sich ein Unternehmen schließlich für die Einführung eines DWH-Systems entscheidet, so ist eine strukturierte Vorgehensweise bei der Einführung sinnvoll, um das DWH-System auch langfristig erfolgreich nutzen zu können. Diese Einführungsweise wird abschließend in Kapitel 3 vorgestellt.

Eine zentrale Analysekomponente im DWH-System bildet das OLAP, das dazu dient, Daten strukturiert und fokussiert darzustellen und so das Management bei deren Entscheidungsfindung zu unterstützen. Hierzu werden die Anforderungen, die OLAP erfüllen muss, um dies zu gewährleisten, abgeleitet. Grundlegende Prinzipien sind dabei die zwölf Regeln nach Codd sowie das Prinzip FASMI. Jedoch findet in Unternehmen nicht nur das klassische OLAP Anwendung. Vielmehr existieren eine Vielzahl von OLAP-Varianten, deren Funktionsweise und Eigenschaften vorgestellt werden. Letztlich stehen bei der Verwendung von OLAP dem Entscheider unterschiedliche Operationen zur Verfügung, um Analysen einfach und eigenständig durchzuführen. Diese Operationen werden in Kapitel 3.3 vorgestellt.

1.2 Lernziele der Einheit „Intelligente Datenhaltung und Datenbereitstellung“

Die **Lernziele** dieser Einheit lassen sich wie folgt zusammenfassen:

- Sie können erklären, was unter dem Begriff DWH verstanden wird und kennen die wesentlichen Aufgaben und Ziele eines DWH.
- Sie kennen die verschiedenen Komponenten und Funktionen eines DWH-Systems und die zugehörige Gesamtarchitektur.
- Sie kennen die verschiedenen Anforderungen, die an OLAP gestellt werden und verstehen die grundlegende Funktionsweise.
- Sie kennen die verschiedenen Ausprägungen von OLAP und verstehen, worauf diese basieren und worin sich die Ausprägungen unterscheiden.
- Sie wissen, welche unterschiedlichen OLAP-Operationen es gibt und wie diese vom Entscheider angewendet werden können.

2 Grundlegende Begriffe und Konzepte

Business Rules oder auch Geschäftsregeln gewinnen in der Praxis zunehmend an Bedeutung. Eine Business Rule kann dabei allgemein definiert werden als ein Regelwerk oder eine Anleitung, die dabei helfen soll, das Alltagsgeschäft zu steuern und zu organisieren (Schacher & Grässle, 2006). Business Rules geben dabei den Weg vor, wie ein Ziel erreicht werden soll. Nach Scheer und Werth sind Business Rules „Richtlinien oder Geschäftspraktiken, die das Verhalten eines Unternehmens beeinflussen oder leiten. Verhalten bedeutet in dem Zusammenhang, mit welchen Prozessen (wie) und mit welchen Ressourcen (womit), welche Produkte erstellt werden“ (Scheer/Werth 2006, S. 52). Im Zusammenhang mit DWHs sind solche Business Rules wichtig, die beispielsweise Vorschriften zur Datenhaltung, Datenbereinigung usw. machen.

Ein weiterer wichtiger Begriff im Zusammenhang mit DWHs ist das Metadatenmanagement. Metadaten sind Daten auf einer übergeordneten Ebene. Das Metadatenmanagement befasst sich mit der Pflege und Wartung dieser übergeordneten Daten. Nur wenn hier bereits eine entsprechende Qualität erreicht werden kann, können auch die „untergeordneten“ Daten effizient gehalten und genutzt werden. In diesem Kapitel werden daher die Begriffe der Business Rules sowie des Metadatenmanagements eingeführt und erläutert.

2.1 Business Rules

Typen von Business Rules

Business Rules können in verschiedene Kategorien unterteilt werden. Schacher und Grässle schlagen dabei die Unterteilung in Ableitungsregeln, Einschränkungen und Prozessregeln vor (Schacher & Grässle, 2006). Ableitungsregeln zeichnen sich dadurch aus, dass die Regeln dadurch entstehen, indem auf bereits bestehende Regeln oder Informationen zurückgegriffen wird und sich dadurch neue Business Rules ableiten lassen. Beispielsweise ist eine Person ein zurückgewonnener Kunde, wenn die Person länger als ein Jahr keine Leistungen oder Produkte bezogen hat und erst nach diesem Zeitraum wieder Produkte oder Leistungen bezieht. Einschränkungen können in der Form von Geboten oder Verboten vorliegen, die zu jeder Zeit gelten. Eine beispielhafte Regel wäre die Folgende: „Ein Neukunde erhält nur bei der ersten Eröffnung eines Bankkontos eine einmalige Prämie“. Prozessregeln werden immer in der Form „wenn xyz dann abc“ formuliert. Sie drücken somit aus, dass ein Sachverhalt oder eine Aktivität eine andere Aktion auslöst. Eine beispielhafte Regel hierfür wäre „Wenn ein Kunde einen Kredit beantragt, muss der Kunde auf seine Kreditwürdigkeit hin überprüft werden“.

Eigenschaften von Business Rules

Unabhängig von der Kategorie der Geschäftsregel müssen Geschäftsregeln verschiedene Eigenschaften aufweisen. Eine Voraussetzung ist, dass sie präzise formuliert werden müssen, sodass für die einzelnen Mitarbeiter kein Interpretationsspielraum möglich ist. Des Weiteren müssen Geschäftsregeln verständlich sein, sodass Mitarbeiter, unabhängig davon, welcher Abteilung sie angehören oder welchen Wissensstand sie haben, ebenfalls die Regeln verstehen können ohne dass sie die Regeln weitergehend interpretieren müssen. Die letzte Eigenschaft einer Geschäftsregel ist, dass sie deklarativ sein muss. Durch diese Eigenschaft ist sichergestellt, dass die Regel lediglich beschreibt, was das zu erreichende Ziel ist, jedoch nicht vorgibt, wie dieses Ziel erreicht werden soll (Schacher & Grässle, 2006).

Geschäftsregeln müssen immer im Kontext der Gesamtunternehmensausrichtung gesehen werden. Die Business Rules Group hat hierzu das Business Motivation Model (BMM) entwickelt, das den Zusammenhang zwischen Geschäftsregeln, der Geschäftspolitik sowie der Unternehmensstrategie abbildet (vgl. hier und im Folgenden (Business Rules Group, The Business Motivation Model - Business Governance in a Volatile World, 2010). Die folgende Abbildung zeigt einen Ausschnitt des BMM.

**Einbettung der
Business Rules in das
Business Motivation
Model**




Abb. 1: Ausschnitt aus dem Business Motivation Model

Quelle: in Anlehnung an (Business Rules Group, The Business Motivation Model - Business Governance in a Volatile World, 2010).

Generell lässt sich das Modell in die beiden Teilbereiche Unternehmenszweck und Wege, um diesen Zweck zu erreichen unterteilen. Der Unternehmenszweck kann entweder die Vision oder das angestrebte Ziel eines Unternehmens sein. Er beinhaltet keine Informationen darüber, wie dieses Ziel oder die Vision erreicht werden kann. Die Vision spiegelt die Vorstellung eines Unternehmens wider, wie es sich in der Zukunft sieht. Auch hier gilt wiederum, dass die Vision nicht den Weg beinhaltet, wie dieses zukünftige Bild des Unternehmens erreicht werden soll. Eine Unternehmensvision ist daher immer langfristig orientiert und betrifft alle Teile des Unternehmens. Die gewünschten Ziele eines Unternehmens betreffen in der Regel lediglich Teile des Unternehmens. So werden für verschiedene Teile spezifische Ziele oder Zielvorstellungen angegeben, die in der Zukunft erreicht werden sollen. Diese Ziele sind daher ebenfalls langfristig und laufend anzustreben. Zudem sind sie im Gegensatz zu den Zielvorstellungen qualitativ und eher allgemein formuliert. Zielvorstellungen zeichnen sich dadurch aus, dass sie eher den kurzfristigen Horizont betreffen und quantitativ sind. Zudem sind Zielvorstellungen immer spezifisch und mit einem genauen Ende versehen. So kann eine Zielvorstellung beispielsweise eine Umsatzsteigerung um 10% im kommenden Kalenderjahr sein. Zielvorstellungen müssen dabei bestimmte Eigenschaften aufweisen, die teilweise bereits genannt wurden. Unternehmen sollten Zielvorstellungen haben, die realistisch und auch zu erreichen sind. Des Weiteren müssen Zielvorstellungen messbar sein. Hierzu müssen Messkriterien definiert werden, die auch objektiv zu erheben und zu überprüfen sind. Dies ist im oben angegebenen Beispiel der Fall. Eine Umsatzsteigerung um 10% ist klar messbar und somit auch überprüfbar. Das letzte Kriterium ist ein fester Zeithorizont, den eine Zielvorstellung haben sollte. Dieser kann absolut, also z. B. ein konkretes Datum (...ist bis zum 01.01.2012 zu erreichen) oder relativ (innerhalb des nächsten Jahres) sein. Somit quantifizieren Zielvorstellungen ein Ziel. Die gesteckten Ziele werden mittels der vom Unternehmen festgelegten Strategie unterstützt. Zielvorstellungen hingegen werden durch Taktiken erreicht. Beides, Strategie und Taktik, sind mögliche Handlungsoptionen eines Unternehmens. Diese sind dem Bereich der Wege, den Unternehmenszweck zu erreichen, der im linken Bereich der Abbildung 2 zu finden ist, zuzuordnen. Hierunter finden sich die Mission eines Unternehmens, die bereits genannten Handlungsoptionen sowie Anweisungen bzw. Vorschriften.

Wege, den Unternehmenszweck zu erreichen, können beispielsweise Ratschläge, Techniken, Restriktionen, Instrumente, Methoden oder Fertigkeiten sein. Dies macht deutlich, dass hierunter nicht die einzelnen Schritte, beispielsweise durch Workflowabbildungen oder Geschäftsprozesse, fokussiert werden, sondern vielmehr die Möglichkeiten des Unternehmens, den Unternehmenszweck zu erreichen. Die Mission eines Unternehmens operationalisiert die Vision. Die Mission ist langfristig ausgelegt und fokussiert primär die Erreichung der Vision. Bestimmt wird die Mission durch die Unternehmensstrategie. Diese gehört zu den Handlungsoptionen. Handlungsoptionen können nur dann erfolgreich sein, wenn genügend Vorschriften vorhanden sind, die steuernd auf die Handlungsoptionen wirken. Zu den Handlungsoptionen gehören jedoch nicht die Geschäftsprozesse. Vielmehr können die Geschäftsprozesse durch die Handlungsoptionen umgesetzt werden. Bei den Handlungsoptionen lassen sich strategische und taktische Handlungen unterscheiden. Die Unternehmensstrategie ist langfristig ausgelegt und umfasst einen breiten Anwendungsbereich. Durch die Strategie werden Taktiken implementiert. Demgegenüber sind Taktiken eher kurzfristig ausgelegt.

Im letzten Teil der Wege, den Unternehmenszweck zu erreichen, stehen die Vorschriften oder Anweisungen. Diese werden in deklarativer Form festgehalten und sind verantwortlich für die Durchsetzung der Geschäftsstruktur sowie für die Kontrolle und die Beeinflussung des Verhaltens. Für Unternehmen ist wichtig, dass sie einerseits nicht zu viele Vorschriften aufstellen, da diese ansonsten zu einschränkend wirken, andererseits müssen genügend Vorschriften existieren, damit potenzielle Einsparungen erkannt werden können. Daher ist es wichtig, eine gute Balance bei der Anzahl der Vorschriften zu finden.

Vorschriften können unterschieden werden in Business Rules sowie die Geschäftspolitik. Die Geschäftspolitik ist wenig strukturiert und eher abstrakt formuliert. Im Gegensatz zu den Business Rules wird vorab kein Standardvokabular festgelegt. Des Weiteren ist die Geschäftspolitik nicht automatisierbar. Die Geschäftspolitik steuert die Geschäftsprozesse und stellt die Basis für die Business Rules dar. Business Rules weisen eher entgegengesetzte Eigenschaften im Vergleich zur Geschäftspolitik auf. So sind sie zwar auch abstrakt, jedoch klar und eindeutig durch die Verwendung von Standardvokabular formuliert und dadurch auch klar strukturiert. Teilweise sind Business Rules auch automatisierbar, beispielsweise innerhalb einer Software. Dies ist jedoch nicht zwingend erforderlich. Weitere Eigenschaften von Business Rules finden sich im Business Rules Manifest (Business Rules Group, Business Rules Manifest: Die Prinzipien der Business Rules Unabhängigkeit, 2003). Regeln müssen explizit sein, d. h. sie dürfen keine impliziten Annahmen über Konzepte oder Fakten als Regeln beinhalten. Des Weiteren müssen Regeln entwickelt, geschützt und verwaltet werden. Dies kann durch ein Business Rules Management gewährleistet werden. Zudem müssen die Regeln von den Fachabteilungen validiert werden können sodass untereinander die Konsistenz der Regeln geprüft werden kann. Häufig bieten sich auch Applikationen an, die die Verwaltung von Regeln unterstützen. Voraussetzung der Applikation ist, dass diese tatsächlich die sich ständig verändernden Geschäftsregeln hinreichend gut unterstützen kann.

Business Rules sollen das Geschäftsverhalten steuern sowie die Geschäftsprozesse führen. Folgende Durchführungslevel sind möglich:

Durchführungslevel

- Strikte Durchsetzung: Bei Nicht-Beachtung der Regel droht eine Strafe.
- Aufgeschobene Durchsetzung: Eine Regel kann zurückgestellt werden, muss jedoch zu einem späteren Zeitpunkt Berücksichtigung finden.

- Vorherige Autorisierung: Diese Arten von Regeln werden normalerweise umgesetzt. Jedoch sind Ausnahmen möglich, ohne dass diese zu einer Strafe führen.
- Ausnahme mit vorheriger Rechtfertigung: Wenn eine Regel nicht beachtet werden soll, muss dies vorab geklärt werden. Es muss gerechtfertigt werden können, weshalb das Einhalten der Regel nicht möglich oder aber nicht sinnvoll erscheint.
- Ausnahme mit Erläuterung: Wenn eine solche Regel nicht beachtet wird, ist eine schriftliche Erläuterung, die die Gründe für die Nichtbeachtung der Regel beinhaltet, erforderlich.
- Richtwert: Die Einhaltung der Regeln ist zwar denkbar, jedoch keinesfalls zwingend erforderlich.

Die Zuordnung der Regeln zu dem jeweiligen Durchführungslevel wird primär durch die taktischen Handlungsoptionen eines Unternehmens festgelegt.

Um Prozesse tatsächlich mit Hilfe der Business Rules steuern zu können, müssen die Regeln in eine formalisierte Implementierungssprache transformiert werden, sodass diese von verschiedenen Applikationen genutzt werden können. Hierzu existieren bereits verschiedene Sprachen wie die Rule Markup Language (RuleML) oder die Business Rule Markup Language (BRML). Mit Hilfe dieser Sprachen kann beispielsweise ein Regelmanagementsystem die Regeln weiter nutzen. Hierzu werden die Regeln zentral in einem Regelrepositorium abgelegt. Wenn die Regeln in verschiedene Applikationen, wie z. B. in einem ERP-System, integriert werden, können diese zur Steuerung von Prozessen genutzt werden (Grob, Bensberg, & Coners, 2008).

Fakten zu Business Rules

Im Jahr 2004 wurde ein Fragebogen zum Thema Business Rules von Experten auf diesem Gebiet beantwortet. Folgende Ergebnisse konnten aus dem Fragebogen gezogen werden (Portal, o.J.).

- Die Anzahl der Business Rules ist nicht quantitativ feststellbar. Jedoch waren sich 96% der Befragten einig, dass die Anzahl stetig steigt. Bei der Formulierung der Regeln sollte so vorgegangen werden, dass zunächst eine kleine Anzahl an Regeln festgesetzt wird, die in folgenden Schritten weiter differenziert werden können (Business Rules Group, Business Rules Manifest: Die Prinzipien der Business Rules Unabhängigkeit, 2003).
- Änderungen in Business Rules werden durchschnittlich jährlich vorgenommen. Dabei kann es verschiedene Ursachen geben. So können Gesetzesänderungen dazu führen, dass Prozesse angepasst werden müssen. Je nach Branche eines Unternehmens können Änderungen an den Business Rules auch häufiger vorgenommen werden. So müssen diese Unternehmen ihre Business Rules teilweise monatlich anpassen, um so auf veränderte Marktbedingungen reagieren zu können. Dies betrifft überwiegend Unternehmen, die stark vom Marketing geprägt sind.
- Einige Typen von Business Rules werden in Unternehmen jedoch nur sehr selten angepasst. Diese sind im Bereich der Legislation (28%), des Marketings und der Verkaufsstrategien (28%) sowie des Domain Expertenwissens (22%) zu finden.
- Ein funktionierendes Business Rules Management steigert die Wahrscheinlichkeit, dass die Kommunikation zwischen den Mitarbeitern funktioniert. So führen beispielsweise veraltete Regeln dazu, dass Mitarbeiter kein einheitliches Begriffsverständnis haben, sodass Mitarbeiter „nicht vom selben reden“. Wie bereits erläutert, sind für verschiedene Bereiche mehr und häufig aktualisierte Business Rules notwendig, was durch ein gutes Business

Rules Management gewährleistet werden muss. Eine weitere Aufgabe ist die gute und klare Dokumentation der Regeln, damit ausscheidende Mitarbeiter implizites Wissen nicht aus dem Unternehmen mitnehmen. Die Problematik entsteht, da Business Rules von den Wissensträgern einer Fachabteilung formuliert werden sollten.

- Der Erfolg von Business Rules sowie vom Business Rules Management kann anhand einiger Faktoren benannt werden. So sollte die Geschwindigkeit, mit der Regeln geändert werden, nicht zu hoch sein. Ein weiteres Problem entsteht, wenn Regeln nicht eindeutig definiert wurden, sodass kein einheitliches Verständnis darüber existiert. Eine schnelle Anpassung ist folglich ein wesentlicher Erfolgsfaktor von Business Rules. Dies kann nur dann gewährleistet werden, wenn die aktuell existierenden Business Rules bekannt sind und wenn klar ist, woher diese Business Rules stammen. Des Weiteren sollte Wissen darüber herrschen, wie die einzelnen Business Rules durchgesetzt werden.

Mögliche Business Rules im Zusammenhang mit der Nutzung von DWHs sind beispielsweise Vorschriften, wann die Daten in das DWH geladen werden oder welche Transformationsregeln es gibt. Zur Festlegung dieser Regeln werden häufig Interviews durchgeführt. Jedoch sind die Business Rules in der Regel sehr unvollständig und schlecht dokumentiert. Eine Lösung hierfür ist z.B. das Business Rules Mining, das ähnlich wie das Data Mining und speziell wie die Rule Induction, funktioniert. Beim Business Rules Mining wird das Verhalten der Systeme wie z. B. die Datenspeicherung oder -pflege „durchschürft“, um daraus mögliche Business Rules ableiten zu können (Moore & Wall, 2000).

Business Rules in DWHs

2.2 Metadatenmanagement

Um ein DWH mit einer hohen Qualität bereitstellen zu können, ist es besonders wichtig, dass die Daten, die darin gelagert werden, ebenfalls eine gute Qualität haben. Denn nur wenn dies zutrifft, kann auch die Qualität des DWH hoch sein. Zunächst sollte daher der Begriff der Metadaten abgegrenzt werden, bevor im Folgenden auf das Metadatenmanagement eingegangen wird.

Die Bedeutung von Metadaten beginnt in den 1960er Jahren und steigt bis heute rapide an. Auch die Definition von Metadaten hat sich über den Zeitverlauf stetig verändert und weiterentwickelt. So bezeichnete der Begriff „Metadaten“ in den 1960er Jahren lediglich Dateinamen sowie Feldnamen. Erst in den 1970er Jahren begann die eigentliche Bedeutung der Metadaten, die nun genutzt wurden, um Daten zu definieren. Hierzu gehören die Relationsbezeichnungen, Attributnamen, Schlüssel- und Domaininformationen. In den 1980er Jahren kam der Begriff „Asset“ auf, der den Begriff „Daten“ zu der Zeit völlig ersetzte. Assets entstehen als eine Art Nebenprodukt bei der Anwendungsentwicklung. Insbesondere in den 1990er Jahren wurden viele Forschungsarbeiten im Bereich der Metadaten getätigt. Ein interessanter Ansatz sind die Metadaten in DWHs. Metadaten in DWHs beschreiben dabei zunächst allgemein alle Eigenschaften und umfassen alle Daten, die nicht zu den eigentlichen Daten gehören. Dabei werden Metadaten in Front Room und Back Room-Metadaten unterschieden. Diese Unterscheidung resultiert vor allem aus den Aufgabenbereichen, in denen die Metadaten genutzt werden (Sen, 2004).

Entwicklung der Bedeutung von Metadaten

Der Begriff „Meta“ hat seinen Ursprung in der griechischen Sprache und be-

Definition „Metadaten“

deutet übersetzt „auf einer höheren Stufe, Ebene befindlich“ oder „übergeordnet“ (Duden 2011). Nach Sen umfasst der Bereich Metadaten die „Analyse der Daten über Daten“ (Sen, 2004). Doch diese Aussage ist wenig differenziert und sollte weiter detailliert werden. So können den Metadaten zwei wesentliche Eigenschaften zugeordnet werden. Diese sind das Beziehungsmerkmal und das Abstraktionsmerkmal. Das Beziehungsmerkmal impliziert, dass Metadaten keine Daten mit einem festgeschriebenen Merkmal sind, sondern vielmehr erst durch konkrete Bezugsdaten interpretierbar ist. Wenn diese Daten nicht bekannt sind, können Metadaten nicht interpretiert werden. Somit können Metadaten vielmehr als relatives Konstrukt gesehen werden. Das Abstraktionsmerkmal schließt die vorherige Definition des Begriffs Meta mit ein. Metadaten beziehen sich auf eine höhere Abstraktionsebene, bei der Eigenschaften der gleichartigen Bezugsdaten beschrieben werden und nicht mehr die einzelnen Bezugsdaten an sich (Melchert, 2004). Durch die beiden Merkmale Beziehungsmerkmal und Abstraktionsmerkmal lässt sich der Begriff Metadaten hinreichend gut charakterisieren.

Klassifizierung von Metadaten

Häufig werden Metadaten weiter klassifiziert. Es finden sich in der Literatur unterschiedliche Ansätze zur Klassifizierung. Eine weit verbreitete Unterscheidung sowohl in der Theorie als auch in der Praxis ist die Unterscheidung in fachliche und technische Metadaten. Die Unterscheidung basiert dabei vor allem auf die Sichten der IT-Abteilung sowie der Fachabteilungen auf die Metadaten. Technische Metadaten werden von Administratoren und Anwendungsentwicklern genutzt. Sie beschreiben die logischen und physischen Datenbankschemata und Datenflüsse zwischen den verschiedenen Datenbanken (Bauer & Günzel, 2001). Technische Metadaten entstehen zumeist bei der Entwicklung, dem Betrieb sowie der Wartung des Datenbanksystems (Auth, 2003). Im Gegensatz dazu dienen die fachlichen Metadaten primär dem Endanwender. Die fachlichen Metadaten beinhalten weniger technische Details, sondern vielmehr betriebswirtschaftliches, unternehmensbezogenes Wissen, wodurch die Interpretation der Daten überhaupt erst ermöglicht werden kann (Melchert, 2004). Dies führt dazu, dass die Aufnahme der fachlichen Metadaten sehr pflegeintensiv ist. Mitarbeiter der Fachabteilungen sammeln täglich durch Erfahrung implizites Wissen, das in explizites Wissen transformiert werden sollte, damit das implizite Wissen nicht zusammen mit dem Mitarbeiter das Unternehmen verlässt. Das explizite Wissen kann in Form von Metadaten gespeichert werden. Dies ist jedoch nicht automatisch möglich, sondern muss manuell erfasst werden. Daher werden fachliche Metadaten häufig auch als unstrukturierte Metadaten bezeichnet (Auth, 2003).

Metadatenkategorien

Die Metadatenkategorien werden üblicherweise nach dem Zweck, für den die Metadaten eingesetzt werden, unterschieden. Dies hat sich insbesondere auch in der Praxis bewährt. Ein weiterer Grund für die Zweckorientierung der Metadaten ist auch, dass nicht alle Daten als Metadaten verwaltet werden, sondern nur die Daten, die tatsächlich zweckgerichtet sind und das Datenobjekt beschreiben (Auth, 2003). Nach Auth ergeben sich acht Metadatenkategorien, die im Folgenden kurz erläutert werden (Auth, 2003), (Melchert, 2004)).

- **Terminologie:** Fachbegriffe sollten definiert und ihre Bedeutung klar festgelegt und normiert werden. Daneben ist die klare Definition der Beziehungen zwischen den Fachbegriffen zwingend notwendig. Zudem sollte die Datenstruktur der Fachbegriffe festgelegt werden.
- **Analyse:** Diese Metadaten enthalten Angaben zu den Datenanalysemöglichkeiten eines Unternehmens. Dies können z. B. Dimensionen, Kennzahlen, Mining-Algorithmen, Berichtsdefinitionen, Verantwortlichkeiten oder Berichtsverwender sein.

- **Organisationsbezug:** In jedem Unternehmen sollten Metadaten vorliegen, die die Verknüpfung der Datenbank-Konstrukte mit der Organisationsstruktur beschreiben. Dies können beispielsweise Berechtigungen, Datenverwender oder Vertraulichkeitsstufen sein.
- **Qualität:** Das Ziel ist es, Daten mit der bestmöglichen Qualität zur Verfügung zu stellen, wobei der Aufwand hierfür dem Nutzen gegenübergestellt werden sollte. An dieser Stelle dienen Metadaten insbesondere zur Messung der Datenqualität, bei der die Qualitätsmerkmale Interpretierbarkeit, Nützlichkeit, Glaubwürdigkeit, zeitlicher Bezug und Verfügbarkeit berücksichtigt werden können.
- **Struktur/Bedeutung:** Datenstrukturen entstehen, wenn mehrere Daten aggregiert werden. Die Aggregation erfolgt, indem Daten, die zueinander in Beziehung stehen, zu einer höheren Metaebene zusammengefasst werden. Diese Metadaten dienen der Benennung und technischen sowie fachlichen Beschreibung von Datenstrukturelementen durch die Eigenschaften Name, Typ, Datentyp, Speicherelementgröße, Ersteller, Erstelldatum, Verwendungszweck etc.
- **Systembezug:** Die Metadaten liefern Angaben zu dem für die Datenverarbeitung verwendeten Informationssystem. Dies können beispielsweise Informationen zur Softwarekomponente, z. B. der Herstellername oder die interne Bezeichnung, zur Version, zum Hersteller (z. B. Name und Kontaktinformationen), zum Rechnernamen oder weitere technische Details sein.
- **Transformation:** Metadaten dieser Kategorie dienen der näheren Spezifizierung von Datentransformationsprozessen innerhalb eines Unternehmens. So können Metadaten über die einzelnen Transformationsschritte, den Verwendungszweck oder dem Ausführungsprotokoll gesammelt werden.
- **Metadatenhistorie:** Durch die Historie können Veränderungen der Metadaten festgehalten werden. Eine Historisierung der Objektdaten kann nur dann erreicht werden, wenn gleichzeitig auch eine Historisierung der Metadaten erfolgt. So war es bei der Umstellung des Postleitzahlensystems sinnvoll, diese Veränderung in den Metadaten zu berücksichtigen. Die Historisierung der Metadaten sollte Angaben zur Version, eine Änderungsbeschreibung, das Änderungsdatum, den Änderungsgrund sowie den Verantwortlichen beinhalten.

Metadaten sind mittlerweile in den meisten Unternehmen verbreitet, jedoch sind viele Unternehmen nicht in der Lage, die Metadaten auch effizient zu nutzen. Häufig sind Metadaten für den Endanwender nur schwierig zu finden, unvollständig oder nicht verständlich. Teilweise werden die Metadaten auch nicht als explizites Wissen abgespeichert, sondern befinden sich lediglich als implizites Wissen in den Köpfen der Mitarbeiter (Holthuis, Der Aufbau von Data Warehouse-Systemen: Konzeption - Datenmodellierung - Vorgehen, 2001). Nur wenn Metadaten eine hohe Qualität aufweisen, können sie die Geschäftsprozesse eines Unternehmens unterstützen (Hüner, Brauer, Otto, & Österle, 2011). Um die Effizienz der Metadaten-nutzung in einem Unternehmen zu erhöhen, sollte ein strukturiertes Metadatenmanagement in das Unternehmen integriert werden. Das Metadatenmanagement dient der Erzeugung, Verwaltung und Bereitstellung von Metadaten (Auth, 2003). Neben den technischen Kriterien müssen bei Metadaten auch insbesondere organisatorische Dimensionen berücksichtigt werden. Hierzu zählen z. B. die Definition von Rollen sowie die Betrachtung von arbeitsteiligen Abläufen. Aber auch die Pflege der Metadaten ist entscheidend für deren effiziente Nutzung. Die Pflegeaktivitäten

Metadatenmanagement

sind dabei nicht einmalig durchzuführen, sondern sollten organisatorisch institutionalisiert werden. Folgende Definition berücksichtigt diese Aspekte: „Metadatenmanagement bezeichnet die Gesamtheit der Prozesse zur zielgerichteten Erzeugung, Bereitstellung, Verwaltung und Nutzung von Metadaten.“ (Melchert, 2004)

Organisatorische Gestaltung des Metadatenmanagements

Einen Überblick über die organisatorische Gestaltung des Metadatenmanagements gibt Auth. Er unterscheidet die beiden Prozesse der Metadatenutzung und des Metadatenmanagements.




Abb. 2: Prozesse des Metadatenmanagements

Quelle: in Anlehnung an (Auth, 2003), S. 188.

Die Metadatenutzung impliziert die beiden Prozesse Anwendung und Entwicklung. Die Anwendung betrifft die Fachabteilungen und beinhaltet im Wesentlichen die Datenanalyse. Dem gegenüber steht die Entwicklung, die primär durch die Systementwicklung beschrieben wird. Dies betrifft die technischen Metadaten. Im Mittelpunkt der Prozesse steht das eigentliche Metadatenmanagement, dem vier Hauptprozesse zugeordnet werden können. Diese sind das Datenqualitätsmanagement, das Datenstrukturmanagement, das Terminologiemanagement sowie das Datenkontextmanagement. Das Datenqualitätsmanagement besteht wiederum aus vier Prozessen, die die Qualitätsplanung, die Qualitätslenkung, die Qualitätsrückkopplung sowie die Qualitätsverbesserung sind. Die Qualitätsplanung und Qualitätslenkung sind durch Kennzahlen und Regeln aneinandergeknüpft. Die Qualitätsplanung legt dabei die Kennzahlen und Regeln fest, die der Qualitätslenkung dienen. Bei der Qualitätsrückkopplung werden für jede Kennzahl Messwerte definiert, anhand derer eine Beurteilung der Qualität erfolgen kann. Das Datenstrukturmanagement besteht aus den Prozessen Bereinigung, Entwicklung sowie Migration. Diese Prozesse hängen stark mit dem Prozess der Systementwicklung zusammen. Im Bereich des Datenkontextmanagements wird der Prozess Kontextplanung durchgeführt. Dabei wird ein Bereitstellungsplan für den zweiten Prozess des Datenkontextmanagements, dem Prozess der Kontextbereitstellung, entwickelt. Im Bereich des Terminologiemanagements, der eng mit dem Bereich der Datenanalyse und somit den Endanwendern der Fachabteilungen verbunden ist, existieren vier Prozesse. Diese sind die Neuerfassung von Terminologien, die durch Begriffsvorschläge der Endanwender ausgelöst werden, die Wiederverwendung von Terminologien, die Änderung sowie die Bereinigung von Terminologien. Nach Auth lässt sich mit Hilfe dieser aggregierten Prozesse die organisatorische Einbettung des Metadatenmanagements hinreichend gut beschreiben.

2.3 Datenqualitätsmanagement

Datenqualität wird von vielen Managern nicht wahrgenommen und erst recht werden die Konsequenzen, die aus einer schlechten Datenqualität resultieren, nicht bedacht. Beispielsweise können häufige Fehler in Datenbanken zu einer erhöhten Kundenunzufriedenheit oder gar Kundenabwanderungsquote führen, was sich wiederum auf die Umsatzzahlen und letztlich erheblich auf den Unternehmenserfolg auswirkt. Des Weiteren kann eine schlechte Datenqualität zu einer sehr langen Datenaufbereitungszeit führen, was wiederum eine Just-in-Time-Fertigung verhindert oder aber Strategieimplementierung erheblich erschwert, da Entscheidungen auf Basis von schwachen Prognosen oder fehlerhaften und alten Daten erfolgen muss (Redman, 1995). Daher ist eine gute Datenqualität zum Treffen von Entscheidungen und zur Analyse der Daten von elementarer Bedeutung. Das Thema Datenqualität stellt jedoch im Rahmen von BI das größte Problem dar. Auf die Frage, wie wichtig Datenqualität im Zusammenhang mit Business Intelligence ist, antworten 88 % der Befragten, dass dieses Thema besondere Relevanz hat. Die Befragten waren 96 Entscheidungsträger aus deutschen, 21 österreichischen und 13 aus Schweizer Unternehmen (Capgemini, 2009).

Definition des Begriffs Datenqualität

Im Folgenden soll zunächst der Begriff der Datenqualität definiert werden. Gemäß *Würthele* wird Datenqualität definiert als „mehrdimensionales Maß für die Eignung von Daten, den an ihre Erfassung/Generierung gebundenen Zweck zu erfüllen. Diese Eignung kann sich über die Zeit ändern, wenn sich die Bedürfnisse ändern“ (Würthele, 2003). Diese Definition zeigt, dass die Qualität der Daten immer subjektiv ist und von dem Verwendungszweck und den jeweiligen Benutzerbedürfnissen abhängig ist. Gemäß *English* (1999, S. 24) lässt sich der Begriff Informationsqualität nicht definieren, ohne dabei die „Kunden“ sowie „Wissensverarbeiter“ zu berücksichtigen. *English* verwendet bei seiner Definition die Begriffe Informations- und Datenqualität synonym. Der Begriff Wissensverarbeiter wird definiert als eine Person, die die Daten zur Ausübung ihrer Haupttätigkeit nutzen muss. Demnach ist diese Person gleichzeitig der Kunde, der die Daten sowie daraus gewonnene Informationen „konsumiert“. Jedoch sind nicht alle Kunden auch Wissensverarbeiter. Anhand der Bedürfnisse der Kunden wird über die Qualität der Daten geurteilt. Alle Mitarbeiter eines Unternehmens, unabhängig von der Abteilung in der sie arbeiten, benötigen bestimmte Informationen zur Ausübung ihrer Tätigkeiten. So müssen beispielsweise Mitarbeiter der Marketingabteilung auf historische Verkaufszahlen zugreifen können. Mitarbeiter im Bereich der Beschaffung nutzen Daten aus einem Enterprise Resource Planning (ERP)-System, um eine Übersicht über den Lagerstand und neue Aufträge zu bekommen. Unter Berücksichtigung dieser beiden Begriffe kann Datenqualität definiert werden als die Attribute der Daten und Informationen, die dazu führen, dass die Mitarbeiter („Wissensverarbeiter“ und „Kunden“) ihre Tätigkeiten ausüben können und somit alle Anforderungen konsistent erfüllt werden. Konsistenz ist ein Hauptproblem im Bereich der Datenqualität. Daten sind genau dann konsistent, wenn die abgerufenen Informationen, egal aus welcher Quelle sie stammen, gleich sind. So sollten beispielsweise die Verkaufszahlen eines bestimmten Bereichs, die im ERP gehalten werden, identisch sein mit den Daten aus z. B. einem DWH. Zudem sollen die Erwartungen aller Mitarbeiter gleichermaßen erfüllt werden und nicht die Erwartungen der Marketingabteilung zu 80 % und die der Vertriebsabteilung zu 90 %. Dabei ist jedoch zu beachten, dass die Anforderungen bzgl. der verschiedenen benötigten Daten unterschiedlich hoch sind. Zur Beurteilung der Datenqualität und zur Messung, Steuerung und Anpassung an die Qualitätsbedürfnisse ist es zwingend erforderlich, Qualitätskriterien zu definieren.

2.3.1 Qualitätskriterien

In einer Studie der Autoren *Wang* und *Strong* (1996) wird gezeigt, welche Datenqualitätskriterien praktische Relevanz haben. Die Studie ist im Wesentlichen zweigeteilt. An einer ersten Umfrage nahmen 25 Endanwender und 112 Studenten mit Endanwendungserfahrungen teil. Das durchschnittliche Alter der Beteiligten lag bei 30 Jahren. Die Teilnehmer sollten in einem ersten Schritt alle Datenqualitätseigenschaften notieren, die ihnen einfallen. In einem zweiten Fragebogen sollten 32 genannte Qualitätseigenschaften in die vier vorgegebenen Kategorien „Aktualität, Genauigkeit, Gültigkeit und Interpretierbarkeit“ eingeordnet werden. Das Ergebnis dieser ersten Umfrage ist eine umfangreiche Liste möglicher Datenqualitätskriterien, die insgesamt 179 Eigenschaften umfasste.

In einer zweiten Umfrage wurden 1.500 Absolventen, die bereits Positionen eingenommen haben, in denen sie Daten zur Entscheidungsunterstützung nutzen müssen, befragt. Die ursprüngliche Liste mit den 179 Eigenschaften wurde auf 118 Eigenschaften reduziert. Die Teilnehmer dieser Umfrage hatten die Aufgabe, allen Eigenschaften eine Bedeutung auf einer Skala von eins bis neun zuzuordnen, wobei eins für sehr bedeutend und neun für unbedeutend steht. Zu den einzelnen Eigenschaften wurden keine genauen Definitionen angegeben. Somit war hier Interpretationsspielraum für die Teilnehmer möglich. Die Rücklaufquote dieser Umfrage lag bei 24 %. Nach der Anwendung einer Faktoranalyse sieht das Ergebnis wie folgt aus (s. Abb. 3).




Abb. 3: Datenqualitätskriterien

In Anlehnung an: Wang und Strong 1996, S. 20.

Intrinsische Datenqualität

Die Datenqualität kann demnach in vier Kategorien eingeteilt werden, wobei jeder dieser vier Kategorien weitere Qualitätseigenschaften untergeordnet werden können. Die **intrinsische** Datenqualität geht von der Qualität von Daten an sich aus. Darunter fallen die Qualitätskriterien Glaubwürdigkeit, Genauigkeit, Objektivität und Reputation. Die Glaubwürdigkeit beinhaltet, inwiefern die Daten als wahr oder glaubhaft angesehen

werden. Genauigkeit bezeichnet die Korrektheit der Daten und wie zuverlässig diese hinsichtlich bestimmter Aufgaben sind. Objektivität bezeichnet, inwiefern die Daten als unvoreingenommen angesehen werden. Und letztlich beinhaltet die Reputation, inwiefern die Anwender den Daten, also der Datenquelle oder den Dateninhalten vertrauen (Treiblmaier, 2010). Somit spiegeln diese Qualitätskriterien die Qualität der Daten an sich wider. Die **kontextabhängige Datenqualität** fokussiert die Qualität hinsichtlich der Anforderungen, die sich aus der Fragestellung bzw. dem Kontext ergeben. Hierunter fallen die Qualitätskriterien Mehrwert, Relevanz, Aktualität, Vollständigkeit und angemessene Menge. Der Mehrwert beschreibt den zusätzlichen Nutzen, der durch die genutzten Daten generiert wird bzw. die Vorteile, die durch das Verwenden der Daten generiert werden. Des Weiteren werden Daten daran gemessen, inwiefern sie bei der Bewältigung von Aufgaben helfen. Diese Eigenschaft wird unter Relevanz zusammengefasst. Ein wichtiger Aspekt ist die Aktualität der Daten. Diese gibt an, inwiefern das Alter der Daten zur Bewältigung von Aufgaben angemessen ist. Das letzte Kriterium zur Beurteilung der Datenqualität ist die Menge, die beinhaltet, inwiefern die Datenqualität für die Bewältigung von Aufgaben angemessen ist (Treiblmaier, 2010). Eine weitere Eigenschaft, anhand welcher die kontextabhängige Datenqualität bemessen wird, ist inwiefern die Daten die Realwelt realistisch nachbilden können. Beispielsweise kann mit der kontextuellen Datenqualität überprüft werden, ob für einen Kunden genügend Informationen gesammelt wurden, um den Kunden mittels dieser Daten entsprechend „nachbilden“ zu können. Dazu würde eine Erfassung des Namens, der Adresse sowie des Geburtsdatums nicht genügen. (English, 1999).

Kontextabhängige Datenqualität

Selbst wenn die zuvor erläuterten Datenqualitätsmerkmale alle hinreichend gut erfüllt wurden, können trotzdem schwerwiegende Fehler entstehen, wenn die **Darstellungs- und Zugangsqualität** nicht die Anforderungen erfüllen. Die Darstellungs- und Zugangsqualität beurteilt die Qualität hinsichtlich der Bedeutung für das gesamte System. Die Daten sollen allen, die die Befugnis haben, zugänglich sein und verständlich dargestellt werden können. Dazu können die Daten anhand von insgesamt sechs Qualitätsmerkmalen bewertet werden. Die Interpretierbarkeit gibt dabei an, inwiefern Daten so vorliegen, dass sie sprachlich verständlich sind und die verwendeten Definitionen und Maßangaben ebenfalls verständlich sind. Dabei bezeichnet Verständlichkeit, inwiefern die Eindeutigkeit der Daten gewährleistet ist. Die konsistente Darstellung ist ein weiteres wichtiges Datenqualitätskriterium. Dieses gibt an, inwiefern die Daten mit zuvor gesammelten Daten kompatibel sind und ob sie immer in demselben Format ausgegeben werden. Daten sollten möglichst übersichtlich und kompakt dargestellt werden. Dies wird anhand des Kriteriums „knappe Darstellung“ gemessen. Die letzten beiden Kriterien fallen unter die Zugangsqualität. Hierzu gehören die Verfügbarkeit der Daten sowie die Zugriffssicherheit. Die Verfügbarkeit gibt an, inwiefern Daten erhalten und schnell erreichbar sind. Zugriffssicherheit bezeichnet, inwiefern Daten vor dem Zugang beschränkt und kontrolliert werden können (Treiblmaier, 2010).

Darstellungs- und Zugangsqualität

Eine schlechte Qualität lässt sich beispielsweise daran erkennen, dass Daten nicht rechtzeitig zur Verfügung stehen, dass Daten so dargestellt werden, dass sie zu Fehlinterpretationen bei den Anwendern führen oder die Interpretation sehr viel Erfahrung oder Fachwissen erfordert, dass Daten im allgemeinen nicht zugänglich sind oder dass Daten falsch miteinander verknüpft werden und so falsche Aussagen erzeugt werden (English, 1999).

Um eine gute Qualität der Daten zu erhalten, muss eine Datenqualitätsanalyse durchgeführt wer-

den, die im Wesentlichen zwei Ziele umfasst: zum einen soll festgestellt werden, wo genau Datenfehler entstanden sind, um diese zukünftig zu vermeiden und zum anderen um Maßnahmen zu definieren, die im Folgenden angewandt werden können, damit die zuvor aufgetretenen Datenfehler vermieden werden (Zwirner, 2008). Um eine möglichst gute Datenqualität zu erhalten, bietet sich ein Datenqualitätsmanagement an.

2.3.2 Qualitätssicherungsstrategien

Generell ist es sinnvoll, dass Unternehmen ein Datenqualitätsmanagement integrieren, um die für das Unternehmen optimale Datenqualität zu erhalten. Dabei bedeutet optimal häufig nicht die bestmögliche Datenqualität, denn es sollte immer auch der nötige Aufwand, der zur Verbesserung der Qualität erbracht werden muss, berücksichtigt werden. Generell basiert das Datenqualitätsmanagement auf dem von *Deming* entwickelten Regelkreis Plan-Do-Check-Act, muss jedoch speziell auf die Kriterien und Besonderheiten der Datenqualität angepasst werden. Der modifizierte Kreislauf wird in 4 aufgezeigt.




Abb. 4: Prozess des Datenqualitätsmanagement

In Anlehnung an: (Apel, Behme, Eberlein, & Merighi, 2009), S.102.

Datenqualitätsmanagement nach *Apel et al.* 2009

Zu Beginn müssen alle Qualitätsziele geplant werden. Dabei müssen die relevanten Qualitätskriterien definiert werden. So kann es beispielsweise für ein Unternehmen die Aktualität besonders wichtig sein, wohingegen für ein anderes Unternehmen die Übersichtlichkeit von besonderer Bedeutung ist, weil viele verschiedene Mitarbeiter Zugriff auf diese Daten haben. Wenn die Qualitätskriterien definiert wurden, müssen Sollwerte für diese Kriterien festgelegt werden. In der nächsten Phase des Zyklus, dem Ausführen oder Do, werden die Ist-Werte der ausgewählten Datenqualitätskriterien ermittelt und in der folgenden Phase „Überprüfen“ mit den Soll-Richtwerten abgeglichen. Sollten dabei signifikant hohe Abweichungen festgestellt werden, so muss in der Verbesserungsphase eine Annäherung des Ist-Wertes an den Soll-Wert erzielt werden.

Total Quality Management nach *English* 1999

Dieses Konzept wurde durch *English* modifiziert und speziell für das Datenqualitätsmanagement angepasst. Demnach sollte Qualitätsmanagement mehr als nur ein Vorgehen oder Plan sein, es sollte ein System sein, welches in den Köpfen der Mitarbeiter ist und „gelebt“ wird (English, 1999). Das von *English* entwickelte Konzept ist

der Abb.zu entnehmen. Demnach unterteilt sich der Gesamtprozess des Datenqualitätsmanagements in fünf Phasen, welche im Folgenden kurz erläutert werden. Für weitere Details sei an dieser Stelle an English (1999) verwiesen.




Abb.5: Total Quality Management-Konzept nach English

Entnommen aus English 1999, S. 70.

Phase 1: Datendefinition und Informationsarchitektur

In der ersten Phase des Gesamtprozesses werden die Daten sowie die Qualität der Informationsarchitektur definiert. Diese Phase ist deshalb wichtig, weil zu Beginn, vor der eigentlichen Datenqualitätssicherung, vorab Standards und Kriterien festgelegt werden müssen, wonach die Daten vorgehalten und bereitgestellt werden.

Phase 2: Beurteilung der Informationsqualität

In der zweiten Phase des Total Quality Management-Prozesses nach English wird die Informationsqualität beurteilt. Die Phase beginnt mit der Identifikation bzw. Bestätigung der in der vorherigen Phase festgelegten Informationsgruppen. Danach werden die Eigenschaften der Datenqualität abgeleitet. Hierzu gehören z. B. die Aktualität, Genauigkeit/Fehlerfreiheit oder Vollständigkeit.

Phase 3: Messung der Kosten

Gemäß English können die Kosten, die sich aufgrund unzureichender Qualität ergeben, messen lassen. Hierzu müssen verschiedene Werte berücksichtigt werden. Hierzu gehören beispielsweise die Verbesserung der Kundenzufriedenheit, Erhöhung der Gewinne oder die Kostenreduktion. Schlechte Datenqualität wirkt sich negativ auf die Kundenbindung aus, denn schlechte Datenqualität führt zu schlechtem Service und schlechter Produktqualität, sodass Kunden abwandern, wodurch sich verlorene Erträge ergeben.

Phase 4: Datenüberarbeitung und -bereinigung

In diesem Schritt werden Daten mit schlechter Qualität, fehlende oder fehlerhafte Daten usw. erkannt und auf den zuvor definierten Standard gebracht, sodass am Ende alle Daten diesem Standard genügen. Um dies zu erreichen, müssen möglicherweise auch Daten mit zu schlechter

Qualität gelöscht werden. Die vierte Phase unterteilt sich in zwei Teilphasen, die Datenüberarbeitung und -bereinigung sowie die Datenaufbereitung. In einem ersten Schritt werden die Datenquellen identifiziert, die aufbereitet oder bereinigt werden sollen. Danach werden die ausgewählten Datenquellen genauer überprüft um möglicherweise Ursachen für die schlechte Datenqualität zu entdecken. Bei einer sehr schlechten Datenqualität ist die allgemeine Idee, die Daten zu standardisieren. Dieser Schritt erfolgt nach der Analyse der Daten. Hierzu müssen, je nach Ursache der schlechten Datenqualität, die Daten entweder korrigiert oder möglicherweise vervollständigt werden. Anschließend werden die Daten der unterschiedlichen Datenquellen miteinander verglichen, sodass möglicherweise redundant gehaltene Daten erkannt werden und dieses Problem folglich behoben werden kann. Das Ergebnis dieser ersten Schritte der vierten Phase sind zum einen die bereinigten Daten der entsprechenden Datenquellen sowie zum anderen die Erkenntnis über die verschiedenen Fehlertypen

Basierend auf den Erkenntnissen über die verschiedenen Fehlertypen werden die analysierten und fehlerhaften Daten transformiert, sodass diese Daten in das vorgegebene Datenformat passen. Danach werden die Daten anhand ausgewählter Kriterien zusammengefasst und berechnet, wie hoch die Abweichungen der zusammengefassten Daten sind, d. h. wie sehr sich die Daten voneinander unterscheiden. Danach erfolgt die Extraktion, Transformation und Ladung in ein DWH oder Data Mart. Durch diese Phase wird sichergestellt, dass die Daten richtig, d. h. in der gewünschten Qualität, in das DWH oder Data Mart geladen werden. Zudem können durch das Vorgehen der vierten Phase Wiederholungsfehler vermieden werden.

Phase 5: Verbesserung der Informationsprozessqualität

Die letzte Phase im gesamten Total Quality Management-Konzept umfasst die Verbesserung der Informationsprozessqualität. Dieser Prozess sollte von Unternehmen am meisten verinnerlicht sein, da er die Ursache der Probleme erkennen sollte und Prozessveränderungen implementiert, um langfristig effiziente Prozesse im Bereich des Qualitätsmanagement sicherzustellen. Wenn durch vorgenommene (z. B. dem „Plan – Do – Check – Act“-Prozess, vgl. Abb.) Änderungen die Informationsqualität zufriedenstellend verbessert werden konnte, werden die Implementierungen für die entsprechenden Unternehmensbereiche übernommen und der Prozess ist erfolgreich abgeschlossen.

Das Gesamtergebnis aller Prozesse des Total Quality Management ist die langfristige Verbesserung der Informationsqualität.

2.3.3 Vorbeugung vor neuen Datenqualitätsproblemen

Generell kann die Datenqualität in insgesamt fünf Schritten nachhaltig verbessert werden. Diese Schritte basieren auf den zuvor erläuterten Kreislauf von *Deming*, wurden jedoch modifiziert. Im ersten Schritt müssen die Datenqualitätsprobleme eindeutig identifiziert werden. Hierzu sollte eine Kosten-Nutzen-Betrachtung durchgeführt werden, sodass die aufgetretenen Fehler und der benötigte Korrekturaufwand abgeschätzt werden können. Im nächsten Schritt müssen für die Datenqualitätskriterien Ziel- bzw. Richtwerte festgelegt werden. Der nächste Punkt ist sehr zeitaufwändig und beinhaltet im Wesentlichen die Analyse der aufgetretenen Datenqualitätsprobleme. In diesem Schritt müssen die Gründe dafür erkannt und in den Prozessen identifiziert werden. Als logische Folge wird in der nächsten Maßnahme der Fehler verursachende Prozess verändert. Nur

wenn dies geschieht, kann der aufgetretene Fehler auch langfristig und vorbeugend behoben werden. Abschließend werden im letzten Schritt die Veränderungen bewertet. Es wird nochmals überprüft, ob der nun erreichte Wert dem gewünschten Wert für das entsprechende Datenqualitätskriterium entspricht oder ob evtl. nochmals Veränderungen im Prozess erforderlich sind (Apel, Behme, Eberlein, & Merighi, 2009).

Eine ähnliche Unterscheidung findet sich in Redman (1995). Der Autor definiert drei Strategien, wie die Datenqualität verbessert werden kann: (1) Fehlererkennung und -korrektur, (2) Prozessmanagement, (3) Prozessdesign. Die Fehlererkennung und -korrektur wurde bereits erläutert. Die Strategien (2) und (3) sollen im Folgenden beschrieben werden.

Strategien zur Verbesserung der Datenqualität

Das Prozessmanagement setzt direkt bei der Ursache der auftretenden Fehler an. Zunächst müssen der Verantwortlichkeitsbereich klar definiert werden, bevor die Kundenanforderungen und Prozesse definiert werden. Danach gilt es, die Messgrößen festzulegen, damit eine Überwachung dieser statistischen Messgrößen erfolgen kann. Parallel hierzu sollte ein Abgleich mit den Kundenanforderungen erfolgen, damit Abweichungen frühzeitig erkannt werden und korrigiert werden können. Der nächste Schritt ist die Analyse des Prozesses und damit einhergehend die Suche nach Verbesserungsmöglichkeiten, die dann in eine Reihenfolge gebracht werden sollten um letztlich die Prozessqualität zu verbessern. Im Fokus sollen dabei immer Prozesse zur Erzeugung von Datenwerten stehen. Eine Möglichkeit zur Überwachung dieser Prozesse basiert auf dem Verfahren der Datenaufbereitung, erweitert dieses jedoch, da viele Fehler nicht erkannt werden. Durch übersichtliche Darstellungen wie Balkendiagramme oder Pareto-Graphiken, können Fehlerquellen erkannt und in einem weiteren Schritt vermieden werden. So kann beispielsweise bei einem mehrstufigen Prozess festgestellt werden, in welcher Phase Fehlerkorrekturversuche häufig scheitern.

Prozessmanagement

Das Prozessdesign hat die Aufgabe, die im Fokus des Prozessmanagement stehenden Prozesse weniger fehleranfällig zu machen. Eine Möglichkeit, die sich häufig zur Beseitigung von Fehlern eignet, ist das Einbinden von IT in den Prozess. Dies sollte immer dann überdacht werden, wenn den Anwendern in immer den gleichen Prozessschritten Fehler unterlaufen. Bei einer Bank können beispielsweise Fehler bei der manuellen Eintragung von Überweisungsträgern unterlaufen, indem eine falsche Kontonummer eingegeben wird. Dies führt dazu, dass die Anforderungen der Kunden, eine schnelle, fehlerfreie Überweisung nicht erfüllt werden können. Eine Möglichkeit, diesen Fehler zu vermeiden, wäre die Einführung eines zusätzlichen Schrittes zur Überprüfung der Richtigkeit der eingetragenen Daten oder aber den ganzen Prozess zu automatisieren, indem Lesegeräte eingesetzt werden. Häufig ist die Einbindung von IT in den Prozess langfristig die bessere Alternative.

Prozessdesign

3 Data Warehouse-Systeme

Um aus Daten Informationen und letztlich Wissen generieren zu können, sind mehrere Schritte notwendig. Das DWH bildet dabei einen elementaren Schritt zwischen der Sammlung der Daten und der Analyse sowie Distribution. Die Sammlung der Daten erfolgt entweder intern in den verschiedenen Geschäftsapplikationen eines Unternehmens. Dies kann beispielsweise ein Enterprise Resource Planning (ERP)-System oder ein Customer-Relationship-Management (CRM)-System sein. Daten können aber auch extern gesammelt werden, indem ein Unternehmen beispielsweise Daten aus einer Marktanalyse generiert.

Nach der Datensammlung werden die Daten in das DWH geladen. Dieser Schritt umfasst mehrere Teilschritte wie die Extraktion, Transformation und Laden der Daten. Danach werden die Daten zur Analyse und Distribution von anderen Applikationen oder Systemen genutzt. Hierzu gehören beispielsweise Data Mining-Anwendungen (vgl. Einheit 2 dieses Lehrbriefs).




Abb. 6: Einbettung von Data Warehouses in den Gesamtkontext der BI
(auch als Speicherarchitektur, engl. Hub and Spoke Architecture, bezeichnet)

3.1 Gesamtarchitektur eines Data Warehouse-Systems

Die Gesamtarchitektur eines DWH-Systems lässt sich in unterschiedliche Ebenen einteilen. Jeder Ebene können eine oder mehrere Komponenten eines DWH-Systems zugeordnet werden. Neben der Darstellung eines DWH-Systems im Kontext der Hub-and-Spoke Architektur (Abb. 6), kann die Architektur eines DWH-Systems auch entlang der enthaltenen Ebenen dargestellt werden. Ein zentrales Beispiel hierfür liefert die Einteilung der Ebenen nach Sinz et al. 2001 (Abb. 7), welche die Analysekomponenten nicht in eine gemeinsame Stufe „Entscheidungsunterstützung“ zusammenfasst, sondern diese nochmal in Datenbereitstellungsebene und Präsentationsebene unterteilt.




Abb. 7: Zusammenfassende Gesamtarchitektur

Außerhalb des DWH-Systems existiert vorgelagert die Ebene der operativen Systeme. Diese Ebene gehört nicht zum eigentlichen DWH-System, sondern beinhaltet die verschiedenen Datenquellen, die Daten in das DWH-System einspeist.

Ebene der operativen Systeme

Die erste eigentliche Ebene im DWH-System ist die Datenerfassungsebene. Diese Ebene weist eine Schnittstelle zu den operativen Systemen auf (Sinz, Böhnlein, Plaha, & Ulbirsch-vom Ende, 2001). Die Daten der Quellsysteme werden physisch in den Bereich des DWH-Systems gebracht. An dieser Stelle wird erstmals die ETL-Komponente benötigt, da die Daten in den Arbeitsbereich extrahiert werden müssen. In diesem Schritt erfolgt somit auch die Bereinigung, Harmonisierung und Zusammenführung der Daten (d.h., Transformation der Daten).

Datenerfassungsebene

In der Datenhaltungsebene ist das Hauptelement das DWH. Nach der Transformation werden die Daten hier also in das DWH geladen (Sinz, Böhnlein, Plaha, & Ulbirsch-vom Ende, 2001). Wie in Kapitel 3.2 beschrieben, erweitert der Operational Data Store (ODS) das DWH.

Datenhaltungsebene

Die Datenhaltungsebene kann in zwei Schichten unterteilt werden. Die Basisschicht beinhaltet Tabellen, die direkt aus den Quellsystemen übernommen werden. In der Aggregationsschicht wer-

den Daten in Tabellen gehalten, die bereits für OLAP-Anfragen optimiert wurden. Hierdurch können Aggregationshierarchien entstehen, bei denen die Anfragen der Benutzer berücksichtigt werden.

Die Datenbereitstellungsebene hat eine Schnittstelle zur nächsten Ebene, der Präsentationsebene (Sinz, Böhnlein, Plaha, & Ulbirsch-vom Ende, 2001). Diese Ebene gehört, wie auch die Ebene der operativen Systeme, nicht mehr zum eigentlichen DWH-System. In dieser Ebene findet die zweckmäßige Aufbereitung der Informationen, die für den Entscheidungsträger relevant sind, statt. Die Analysekomponente befindet sich einerseits auf der Ebene der Datenbereitstellung, da beispielsweise OLAP die Daten so selektiert und aufbereitet, dass der Entscheider diese für seine Analysen nutzen kann. Andererseits gehört die Analysekomponente auch zur folgenden Präsentationsebene.

Datenbereitstellungsebene

Präsentationsebene Die Aufgabe der Präsentationsebene ist die adäquate Aufbereitung und insbesondere Präsentation der Daten. Dies erfolgt mittels der Analysekomponente. So können beispielsweise verschiedene Data Mining-Anwendungen die Daten entsprechend aufbereiten. Auch können Tabellenkalkulationsprogramme bei der Präsentation der Informationen helfen (Goeken, 2006). Zudem müssen die Erfolgsgrößen kritisch überwacht werden, sodass bei einer Überschreitung kritischer Wertgrenzen eine Benachrichtigung an den Entscheidungsträger gesendet wird. Hierbei kann beispielsweise Data Access helfen (Goeken, 2006).

3.2 Definition und Ziele eines Data Warehouse

Definition nach Inmon: SINT-Eigenschaften

Bill Inmon wird als Vater des DWH-Konzepts bezeichnet. Gemäß seiner Definition ist ein DWH „a subject-oriented, integrated, nonvolatile, and time-variant collection of data in support of management’s decisions“ (Inmon, 2000). Somit zeichnet sich ein DWH durch die Eigenschaften Themenorientierung, Integration, Zeitraumbezug sowie Nicht-Volatilität aus. Entsprechend der englischen Übersetzung werden diese Eigenschaften als die **SINT-Eigenschaften** abgekürzt. In jedem Unternehmen können verschiedene Themengebiete identifiziert werden. Dies können z. B. Kunden, Produkte, Mitarbeiter usw. sein. In einem DWH werden die Daten nun themenorientiert gehalten. Im Gegensatz dazu wurden Daten früher an den Applikationen eines Unternehmens orientiert gehalten. In einem DWH werden Daten aus verschiedenen Datenquellen integriert. Eine Integration der Daten stellt sich in der Praxis häufig als schwierig dar, weil die verschiedenen Applikationen eines Unternehmens die Daten jeweils unterschiedlich ablegen. Beispielsweise kann in einer Applikation das Geschlecht als „männlich“, „weiblich“, in einer anderen Applikation abgekürzt als „m“ und „w“ und in wiederum einer weiteren Applikation als „1“ und „0“ bezeichnet werden. Dieses Beispiel macht deutlich, dass die Integration sich als sehr aufwändig gestalten kann. Neben der Kodierung der Daten ist die Maßangabe von Attributen eine weitere mögliche Herausforderung bei der Integration der Daten (Inmon, 2000). Beispielsweise können Produktattribute in der einen Applikation in Kilogramm und Zentimeter, in einer anderen aber in Tonnen und Meter angegeben werden. Somit zeigt sich deutlich, dass diese Problemfelder erkannt und systematisch behoben werden müssen, um widerspruchsfreie Daten zu erhalten (Kemper, Baars, & Mehanna, 2010). Die dritte Eigenschaft eines DWH ist der Zeitraumbezug. Im Gegensatz zu den Daten in Applikationen werden die Daten in DWHs nicht zeitpunktbezogen sondern zeitraumbezogen abgelegt. Ein DWH ermöglicht es somit,

dass Daten langfristig vorgehalten werden mit einem Zeithorizont von fünf bis zehn Jahren. Operative Systeme, wie sie im Tagesgeschäft eines Unternehmens verwendet werden, müssen hingegen immer aktuelle Daten vorliegen haben. Beispielsweise müssen die Informationen zu den Transaktionen eines Kunden aktuell vorliegen, wohingegen diese Daten im DWH eher über den Zeitraum hinweg abgelegt werden. Die Daten in einem DWH sind somit nur unmittelbar nach dem Laden der Daten in das DWH aktuell (Gray & Watson, 1998). Diese Eigenschaft eines DWH ist jedoch nicht mehr aktuell und wurde durch die Eigenschaft Granularität ersetzt. Mittlerweile ist es in der Praxis weit verbreitet, dass sogar die Daten im DWH transaktionsbezogen abgespeichert werden (Kemper, Baars, & Mehanna, 2010). Die letzte Eigenschaft eines DWH ist die Nicht-Volatilität. Diese Eigenschaft besagt, dass Daten dauerhaft vorgehalten werden und nicht vergänglich sind. Einmal abgelegte Daten werden nicht aktualisiert, sondern vielmehr erneut hochgeladen. Dies führt dazu, dass auch Daten aus der Vergangenheit abrufbar bleiben. In CRM-Systemen beispielsweise wird der veraltete Wohnort durch den aktuellen Wohnort eines Kunden überschrieben. Somit geht der alte Wert verloren. Im DWH hingegen bleiben beide Werte erhalten. Dies hat den Vorteil, dass diese veralteten Informationen zwar genutzt werden können, jedoch ist ein wesentlicher Nachteil, dass in dem DWH ein enormes Datenvolumen vorgehalten wird (Inmon, 2000), (Kemper, Baars, & Mehanna, 2010)).

DWHs sind dispositive Datenhaltungssysteme und werden von den operativen Datenhaltungssystemen separiert betrachtet (Kemper, Baars, & Mehanna, 2010). Um diese Aussage zu verstehen, ist eine Abgrenzung von operativen und dispositiven Daten notwendig. Abbildung 8 gibt eine Übersicht über die Eigenschaften von dispositiven und operativen Daten und stellt diese gegenüber (s. hierzu auch Einheit 1 dieses Lehrbriefs).

Abgrenzung von dispositiven und operativen Daten




Abb.8: Dimensionen von operativen und dispositiven Daten

Quelle: in Anlehnung an (Kemper, Baars, & Mehanna, 2010).

Die Abbildung 3 verdeutlicht, dass die Dimensionsausprägungen der dispositiven Daten der Definition von DWH nach Inmon stark ähneln. So wird die Dimension „Ausrichtung“, die bei dispositiven Daten meist stark verdichtet oder bzw. und transformiert sind, durch die Eigenschaft Integration abgedeckt. Die Integration umfasst unter anderem die Transformation der Daten, die ein wesentliches Kriterium der Ausrichtung sind. Der Zeitbezug bei dispositiven Daten ist historienbetrachtet, d. h. die Daten werden über einen längeren Zeitverlauf und nicht zeitpunktbezogen betrachtet. Diese Ausprägung geht einher mit der Eigenschaft des Zeitbezugs, aber auch mit der Nicht-Volatilität, die, wie oben beschrieben, besagt, dass Daten dauerhaft vorgehalten werden und nicht vergänglich sind. Die Modellierung bei dispositiven Daten erfolgt sachgebiets- sowie themenorientiert, was an sich bereits eine Eigenschaft eines DWH ist. Der Zustand von dispositiven Daten kann als kontrolliert redundant und konsistent beschrieben werden. Demzufolge müssen Daten bereits integriert sein, sodass Redundanzen sowie Inkonsistenzen behoben wurden. Letztlich sollen dispositive Daten der Entscheidungsunterstützung dienen. Folglich sind die Daten eher auf der Ebene des Managements anzusiedeln und nicht, wie die operativen Daten, zur Unterstützung des Tagesgeschäfts, also auf Abteilungsebene. Daher wären operative Daten, die im Tagesgeschäft generiert und genutzt werden für managementunterstützende Systeme wenig hilfreich und zielführend (Kemper, Baars, & Mehanna, 2010).

Ziele eines Data Warehouse

Die Ziele eines DWH können wie folgt zusammengefasst werden. Ein DWH hat das Ziel, Daten, die häufig in sehr großen Mengen vorliegen, für die Durchführung von Auswertungen und Analysen effizient bereitzustellen (Behme & Muksch, 2001). Hierzu zählt auch, dass Daten zu Analysezwecken einfach zusammengeführt werden können (Totok, 2000). Ein weiteres Ziel ist, dass durch die Verwendung eines DWH die Geschäftsprozesse eines Unternehmens unterstützt werden müssen, um so zur Strategieerreichung eines Unternehmens beitragen zu können. Ein DWH kann z. B. bei der Analyse der Geschäftsprozesse helfen und diese optimieren (vgl. hierzu auch Abschnitt 13262638082.1) (Behme & Muksch, 2001). Ein letztes Ziel ist die Abschaffung von Insellösungen. Insellösungen führen dazu, dass einzelne Aufgabenbereiche untereinander nur schwierig miteinander kommunizieren können (Totok, 2000). Alle genannten Ziele können erreicht werden, indem die oben genannten und erläuterten Eigenschaften eines DWH eingehalten und sinnvoll in ein Unternehmen implementiert werden.

Ein DWH umfasst lediglich die Datenbasis. Diese muss jedoch in ein DWH-System eingebettet werden, damit die Datenbasis sinnvoll zu Analysezwecken genutzt werden kann. Ein DWH-System sorgt dafür, dass die genannten Eigenschaften eines DWH den Anwendern zur Verfügung gestellt werden können. Neben der Analyse der Daten zählen hierzu die Datenbeschaffung sowie das DWH (Bauer & Günzel, 2001). Ein DWH-System dient primär der Unterstützung der Leistungsprozesse einer Organisation. Dabei sollte die Organisationsstruktur berücksichtigt werden. Je nach Organisationsstruktur sollte die Ausgestaltungsform des DWH-Systems entsprechend ausgewählt werden (Sinz, Böhnlein, Plaha, & Ulbirsch-vom Ende, 2001).

3.3 Komponenten eines DWH-Systems

Ein DWH-System besteht aus verschiedenen Komponenten, die insgesamt die Eigenschaften sowie Aufgaben und Ziele eines DWH-Systems erfüllen. Je nach Autor werden verschiedene Komponenten unterschieden. Die folgenden genannten Komponenten bilden eine Schnittmenge verschiedener Autoren (Bauer & Günzel, 2001), (Behme & Muksch, 2001), (Holthuis, Der Aufbau

von Data Warehouse-Systemen: Konzeption - Datenmodellierung - Vorgehen, 2001)):

- DWH
- Operational Data Store (ODS)
- Arbeitsbereich
- Extraktion – Transformation – Laden (ETL)-Komponente
- Metadatenbanksystem
- Analysekomponente

DWH

Die Datenbasis oder auch das DWH ist der Kern eines jeden DWH-Systems und hat drei Funktionen. Das DWH sammelt die Daten aus den verschiedenen Datenquellen eines Unternehmens und stellt diese zentral zur Verfügung. Somit kommt dem DWH eine Sammel- bzw. Integrationsfunktion zu. Im nächsten Schritt können die gesammelten Daten an das DWH-System im Unternehmen verteilt werden. Daher hat das DWH auch eine Distributionsfunktion. Die letzte Funktion ist die Auswertungsfunktion. Das DWH kann einzelne Analysen der aus den Datenquellen gesammelten Daten durchführen (Bauer & Günzel, 2001).

Operational Data Store

Die Komponente ODS ist eng mit dem DWH verknüpft. Der ODS geht wie auch das DWH auf Inmon (2000) zurück, der diese Komponente wie folgt definiert: *„Ein ODS ist eine themenorientierte, integrierte, nicht dauerhafte bzw. nicht persistente detaillierte Sammlung von Daten, um eine Organisationseinheit bei ihrem Bedarf nach aktuellen, betrieblichen, integrierten und gesamtgesellschaftlichen Informationen zu unterstützen.“* Ein ODS ist also eine Datenbank, die der Integration von Daten aus einer oder mehreren Datenquellen dient. Hierzu werden die aus den Datenquellen relevanten Daten extrahiert und gegebenenfalls wegen Redundanzen und verletzter Integritätsbedingungen bereinigt und transformiert. Im ODS werden die Daten für in der Regel zeitnahe Auswertungen bereitgestellt, die in den Quellsystemen nicht oder nur schwer möglich sind. Ein Anwendungsbeispiel ist die Angebotserstellung in Abhängigkeit zeitnaher Börsenkurse.

ODS erweitern die Funktionsweise eines DWH dahingehend, dass durch die Nutzung eines ODS eine transaktionsorientierte und integrierte Datenhaltung ermöglicht wird (Kemper, Baars, & Mehanna, 2010).

Arbeitsbereich (staging area)

Im Arbeitsbereich oder auch staging area werden Daten temporär zwischengespeichert. Dies soll verhindern, dass das DWH sowie die Datenquellen im laufenden Betrieb beeinträchtigt werden (Bauer & Günzel, 2001). Bevor die Daten im DWH gespeichert werden, müssen sie im Datenbeschaffungsbereich des DWH-Systems aufbereitet werden. Der Arbeitsbereich stellt die zentrale Komponente dieses Datenbeschaffungsbereichs dar. Er dient vornehmlich dazu, die Daten aus den verschiedenen Datenquellen nach bestimmten zuvor festgelegten Regeln zu transformieren und zu integrieren (Farkisch, 2011). Hierzu hängen der Arbeitsbereich und die im Folgenden beschriebene ETL-Komponente stark zusammen. Wenn alle Daten entsprechend transformiert und integriert wurden, werden sie in das DWH geladen und abschließend aus dem Arbeitsbereich gelöscht (Bauer & Günzel, 2001).

Die ETL-Komponente

Eine wesentliche Aufgabe eines DWH ist es, die vielen Daten aus den unterschiedlichen Datenquellen zu vereinheitlichen, zu konsolidieren und in gebündelter Form den Endanwendern zur Verfügung zu stellen. Hierzu ist ein Prozess notwendig, der die Daten zunächst aus den Quellsystemen extrahiert, diese dann in ein einheitliches Format transformiert und schließlich in das DWH lädt. Dieses Vorgehen wird als ETL-Prozess, bezeichnet. Zur Unterstützung dieses Prozesses gibt es im DWH-System eine eigene Komponente, die ETL-Komponente. Diese unterstützt den gesamten Prozess (Strohmeier, 2008), der im Folgenden erläutert wird.



Abb.9: Der ETL-Prozess

Die wesentlichen Aufgaben in einem DWH werden durch den ETL-Prozess abgedeckt. Insgesamt ist dieser Prozess sehr komplex und umfangreich und dient der Sicherstellung einer guten Datenqualität im DWH. Zur Unterstützung des ETL-Prozesses gibt es für jede Aufgabe des Prozesses eine eigene Komponente. Häufig wird der ETL-Prozess in einem Unternehmen durch eine eigene ETL-Anwendung unterstützt. Im Folgenden werden die einzelnen Phasen des Prozesses erläutert, um abschließend den Prozess im Ganzen zu betrachten und kurz auf mögliche ETL-Anwendungen einzugehen.

Extraktion

Der ETL-Prozess beginnt mit der Extraktion der Daten. In dieser Phase werden die Daten von der Datenquelle in den zwischengelagerten Arbeitsbereich übertragen. Eine der Schwierigkeiten in dieser Phase liegt in der Auswahl der Daten, die es zu extrahieren gilt (Bauer & Günzel, 2001). In diese Entscheidung fließen zwei Faktoren ein. Zum einen muss die Beschaffenheit der Daten berücksichtigt werden. Beispielsweise sollten sehr fehlerhafte oder fehlende Daten nicht übertragen werden. Zum anderen ist die Relevanz der Daten von Bedeutung. Hierzu ist es notwendig, dass der Anwender weiß, für welches Ziel die Daten verwendet werden sollen. Somit kann der Anwender die Daten dahingehend auswählen, ob diese für die Erreichung des Ziels verantwortlich sind (Bauer & Günzel, 2001) (weitere Ausführungen zur Selektion der Daten s. Einheit 2 dieses Lehrbriefs, Kap. 3.2). Die Extraktion der Daten sollte möglichst automatisiert erfolgen. Wenn Fehler auftreten, so sollte nicht der gesamte Prozess von neuem starten. Vielmehr sollte eine abschließende Fehlerauslesung möglich sein, sodass die gefundenen Fehler im Nachhinein korrigiert werden können (Navrade, 2008). Neben der Entscheidung, welche Daten extrahiert werden sollen, stellt sich für den Entscheider auch die Frage, wie häufig dies erfolgen soll. Dabei lassen sich vier verschiedene Vorgehensweisen unterscheiden. Eine Extraktion kann periodisch, also in regelmäßig festgesetzten Zeiträumen, durchgeführt werden. Dabei hängt der Zeitraum maßgeblich vom Zweck sowie den Anforderungen ab. Beispielsweise könnten Verkaufsdaten jeden Abend extrahiert werden, wohingegen Börsenkurse minütlich übertragen werden sollten. Die zweite Möglichkeit ist die anfragegesteuerte Extraktion. Hierbei werden Daten

durch einen Anstoß extrahiert. Dies kann z.B. der Fall sein, wenn eine wichtige Veränderung der Daten vorliegt, beispielsweise wenn ein neues Produkt in das Sortiment aufgenommen wurde. Die dritte Möglichkeit ist die ereignisgesteuerte Extraktion. Diese wird automatisch angestoßen, wenn z. B. eine bestimmte, zuvor festgelegte Anzahl an Veränderungen in den Datensätzen vorliegt oder aber auch, wenn ein bestimmter Grenzwert eines Datensatzes erreicht wurde. Beispielsweise kann eine ereignisgesteuerte Extraktion ausgelöst werden, wenn eine bestimmte Umsatzgrenze erreicht wurde. Die letzte Möglichkeit der Extraktion ist die sofortige Durchführung nach einer Veränderung. Somit sind die Daten im DWH immer aktuell. Diese Möglichkeit ist sehr aufwändig und sollte nur bei zeitkritischen Veränderungen erfolgen. So kann eine sofortige Extraktion bei einer Veränderung der Börsenkurse sinnvoll sein (Bauer & Günzel, 2001).

Vor der Ladung der Daten in das DWH erfolgt die Transformation. In dieser **Transformation** Phase werden die Daten so angepasst, dass sie in das DWH geladen werden können. Dabei kann die Anpassung der Daten verschiedene Aufgaben umfassen. Beispielsweise müssen die Daten in den meisten Fällen standardisiert werden, sodass die Daten einheitlich erfasst werden. Hierzu gehört z. B. die Vereinheitlichung von Zeichenketten oder die Konvertierung von Kodierungen. Des Weiteren werden bei der Transformation fehlerhafte Daten durch z. B. fehlerhafte oder unterschiedliche Eingaben durch den Benutzer bereinigt, sowie redundante oder veraltete Daten gelöscht (Bauer & Günzel, 2001). Die unterschiedlichen Datenfehler sowie der Aspekt der Transformation wurden bereits ausführlich in Einheit 2 dieses Lehrbriefs (Kap. 3.2.2 sowie 3.3.1) diskutiert und werden daher an dieser Stelle nicht weiter ausgeführt.

Die letzte Phase des ETL-Prozesses umfasst im Anschluss an die Transformation **Laden** das Laden der Daten in das DWH (Bauer & Günzel, 2001). Bei den Ladephasen wird unterschieden zwischen dem ersten Laden zur Initialisierung des DWH und den späteren, regelmäßigen Aktualisierungen (Bauer & Günzel, 2001). In der ersten Ladephase, auch initiales Laden genannt (Vasile & Mirela, 2008), werden die Daten von den Quellsystemen in das DWH geladen. Diese Art der Ladung wird nur einmalig durchgeführt. Danach bleiben die Daten für einen sehr langen Zeitraum im DWH. Bei der zweiten Ladephase erfolgt die Ladung von Daten aus der Datenbank in das DWH. Dies wird auch als Aktualisierung bezeichnet. Die Daten werden in regelmäßigen Abständen „aufgefrischt“, indem aktuelle Daten in das DWH geladen werden. Der Ladevorgang ist jedoch sehr zeitintensiv bzw. fordert enorme Rechenleistung, was die Effizienz anderer Systeme negativ beeinträchtigen kann, sodass dieser Ladevorgang häufig außerhalb der Auslastungshöhen liegt, z. B. am Wochenende oder über Nacht (Bauer & Günzel, 2001). Die Daten werden nach dem Laden in das DWH jedoch nicht gelöscht, sondern im DWH gehalten, sodass eine Historisierung der Daten sichergestellt werden kann (Navrade, 2008).

Metadatenbanksystem

Ziel eines DWH ist es, dass Mitarbeiter auf die für sie relevanten Daten zugreifen und diese zu Analysen nutzen können. Damit dieses Ziel ermöglicht werden kann, existiert eine Metadatenbank als eine zentrale Komponente im DWH-System, die das Fundament des DWH bildet.

Eine Metadatenbank ist ein Bestandteil im Metadatenbanksystem, das auch als Business Data Directory bezeichnet wird. Die Aufgabe des Metadatenbanksystems ist es, dem DWH Hintergrundinformationen über Datenquellen, Transformationen und Verdichtungen zu liefern. Die hierzu be-

nötigten Informationen werden im Metadatenbanksystem gespeichert. Dabei können die Informationen unterteilt werden in datenverarbeitungstechnische und betriebswirtschaftliche Informationen. Das Ziel des Metadatenbanksystems ist es, Transparenz zu schaffen sowie die Mitarbeiter insbesondere im Bereich der Datenverarbeitung sowie die Mitarbeiter, die für den Betrieb zuständig sind, zu unterstützen. Hierzu bestehen im Metadatenbanksystem zwei Komponenten. Zum einen gibt es einen Informationskatalog, der für alle Anwender eine Hilfestellung bieten soll. Der Informationskatalog beinhaltet Informationsobjekte und beschreibt diese so, dass sie für den Endbenutzer verständlich sind. Informationsobjekte können Grafiken, Tabellen, Texte, vorgefertigte Abfragen, Programme oder Dateien sein. Zum anderen gibt es eine Navigationshilfe in Form eines Browsers. Die Navigationshilfe unterstützt die Anwender bei der Navigation, sodass diese selbstständig in den Metadaten suchen, recherchieren und analysieren können.

Neben diesen beiden grundlegenden Funktionen sollten dem Endbenutzer weitere Informationen zur Verfügung stehen. So muss es beispielsweise ein Lexikon geben, in dem alle Namen der existierenden Datenobjekte sowie deren Abkürzungen in alphabetischer Reihenfolge aufgeführt werden. Des Weiteren sollte es einen Thesaurus geben, sodass die Endbenutzer Synonyme für Datenobjekte sowie die dazugehörigen Charakteristika erkennen können. Ein Datenstrukturverzeichnis beinhaltet alle Daten, die im DWH gehalten werden. Des Weiteren sollte es ein Glossar geben, das alle verwendeten Begriffe, Definitionen und Abkürzungen in alphabetischer Reihenfolge beinhaltet. Zudem sollte eine Übersicht vorliegen, welche Organisationseinheit auf welche Datenquellen zugreift und welche bisher unveröffentlichten Dokumente in den Organisationseinheiten existieren. Diese Informationen werden in einem Data Directory zusammengefasst, welches zusätzlich Projekte, die mit dem DWH in Zusammenhang stehen sowie deren Ansprechpersonen, beinhaltet (Muksch, 2006).

Analysekomponente

Die letzte fehlende Komponente im DWH-System ist die Analysekomponente. Wie der Name bereits sagt, liegt die Hauptaufgabe der Analysekomponente darin, den Benutzer bei der Auswertung der Daten zu unterstützen. Dies kann durch verschiedene Werkzeuge und Tools erfolgen. Hierzu gehören die in Einheit 2 dieses Lehrbriefs bereits eingeführten Methoden des Data Mining. Des Weiteren sind Data Access, OLAP-Verfahren (s. Abschnitt 4) sowie Data Marts einzuordnen (Bauer & Günzel, 2001), (Farkisch, 2011)).

Data Access

Data Access sind Berichtswerkzeuge, die lediglich Daten lesen sowie einfache Operationen durchführen können und die Daten zu Präsentationszwecken aufbereiten können. Bei der Präsentation wird häufig auf die Ampelfunktion zurückgegriffen, bei der verschiedene Farben für verschiedene Größen verwendet werden. So können beispielsweise bei der Darstellung von Umsatzveränderungen negative Veränderungen in Rot, konstante Umsatzzahlen in Gelb und positive Umsatzveränderungen in Grün ausgegeben werden. Dadurch erhält der Anwender schnell einen guten groben Überblick über die Daten. Diese Funktionalität kann mehr als die drei genannten Farben beinhalten und ist auf Tabellen, Grafiken oder Landkarten anwendbar (Bauer & Günzel, 2001).

OLAP

Mittels OLAP können Daten, insbesondere in quantitativen Berichten, darge-

stellt werden. OLAP zeichnet sich besonders durch die Möglichkeit der multidimensionalen Analyse aus, die überwiegend Kennzahlen verwendet, bei der der Anwender selber die Analyse Kriterien bestimmen kann. Ein Vorteil ist auch, dass der Anwender durch relativ einfache Bedienung ein breites Spektrum an Analysemöglichkeiten zur Verfügung hat (Bauer & Günzel, 2001).

Data Marts helfen dem Benutzer bei der Analyse, indem sie eine Exploration der Daten vornehmen. Data Marts „sind spezielle analyseorientierte Systeme mit einer Ausrichtung auf das jeweilige Anwendungsthema“ (Farkisch, 2011), d. h. es können beispielsweise einzelne Data Marts für verschiedene Abteilungen existieren, die abteilungsspezifische Daten für die Auswertungen bereitstellen.

| Data Mart |

3.4 Data Marts

Je nach Organisationsform kann das DWH unterschiedlich ausgestaltet werden. So bietet es sich für einige Unternehmen an, lediglich ein DWH einzuführen, wohingegen andere Unternehmen Data Marts einsetzen sollten.

Viele Unternehmen bevorzugen **Data Marts** gegenüber einem zentralen DWH. Anstelle eines zentralen DWH werden Data Marts verwendet, die kleinen autonomen DWHs entsprechen (Farkisch, 2011). Data Marts haben eine eigene Datenhaltung in Form einer spezialisierten analytischen Datenbank und sind speziell auf die Bedürfnisse von Fachabteilungen oder bestimmten Benutzergruppen zugeschnitten (Hiestermann, 2008). Die Daten, die in den einzelnen Data Marts gehalten werden, stammen meistens aus dem zentralen DWH, bilden jedoch immer nur die entsprechend erforderlichen Daten zur Entscheidungsunterstützung für die jeweilige Benutzergruppe oder Fachabteilung ab (Schmidt-Volkmar, 2008). So werden in den Data Marts lediglich Ausschnitte aus dem zentralen DWH abgebildet, beispielsweise Daten zu den Verkaufszahlen für einen bestimmten Zeitraum (Farkisch, 2011).

Grundsätzlich unterscheiden sich Data Marts und DWHs in ihren Eigenschaften grundlegend. Wie bereits erläutert, ist der Adressat eines Data Marts eine Fachabteilung oder einzelne Entscheidungsgruppen, wohingegen bei einem DWH die Daten nicht speziell für eine Personengruppe zur Verfügung gestellt werden, sondern vielmehr zentral unternehmensweit. Somit gibt es unternehmensweit meistens mehrere Data Marts, je nach Anzahl der Fachabteilungen, wohingegen es in der Regel nur ein einziges zentrales DWH im Unternehmen gibt. Diese Ausprägungen haben einen Einfluss auf die Datenmenge und den Detaillierungsgrad. Durch die zentrale Datenhaltung im DWH werden sämtliche zur Verfügung stehende Daten gespeichert. Dies führt zu einem sehr hohen Datenvolumen. Dadurch, dass in einem Data Mart die Daten gezielt den Bedürfnissen der entsprechenden Anwender angepasst werden, kann das Datenvolumen reduziert werden. Dies wirkt sich ebenfalls auf den Detaillierungsgrad der Daten aus. So liegen die Daten im zentralen DWH in der Regel in einer sehr kleinen Detaillierung vor, wohingegen die Daten des Data Marts häufig auch in aggregierter Form, z.B. in Form von Kennzahlen oder nur für einen bestimmten Zeithorizont oder eine bestimmte Produktgruppe, bereits zusammengefasst werden können. Daraus ergibt sich zwangsläufig, dass in einem zentralen DWH viele historische Daten abgespeichert werden, wohingegen diese bei Data Marts in der Regel nicht benötigt und folglich dementsprechend auch nicht gespeichert werden. Hiermit hängt auch der Einfluss von externen Datenquellen zusammen. Bei Data Marts ist dieser in der Regel nicht gegeben. In einem zentralen DWH ist der

Einfluss externer Datenquellen jedoch sehr hoch, da hier möglichst viele Daten für die Analyse bereitgestellt werden sollen. Häufig können Daten aus externen Datenquellen zu einer Verbesserung der Qualität innerhalb der Analysen beitragen.

Dadurch, dass in einem Data Mart die Daten für eine bestimmte Gruppe zur Verfügung gestellt werden, muss sichergestellt werden, dass diese auch einen direkten Zugriff auf die Daten haben. Bei einem zentralen DWH ist es in der Regel so, dass die Endanwender keinen Zugriff auf die Daten haben. Unternehmen haben häufig schlechte Erfahrung damit gemacht, dass Anwender aufgrund individueller Fehler die Performance des gesamten zentralen DWH durch fehlerhafte oder ineffiziente Abfragen negativ beeinflusst haben. Dies hat dazu geführt, dass häufig nur noch die IT-Abteilung einen direkten Zugriff auf die Daten und entsprechende Analysemöglichkeiten hat, um diese Ineffizienzen zu umgehen (Kemper, Baars, & Mehanna, 2010). Dennoch sind die jeweiligen Fachabteilungen selber für die Pflege und den Betrieb der Data Marts zuständig (Farkisch, 2011). Dies führt dazu, dass die Modellierungskonventionen eher heterogen sind, da jede Abteilung ihre individuellen Konventionen hat. Teilweise werden jedoch einheitliche Konventionen des zentralen DWH übernommen. Im zentralen DWH liegen klare, einheitliche Modellierungskonventionen vor. Die Freiheitsgrade der Analysen sind in Data Marts zumeist sehr beschränkt. Die Anwender haben meist nur Zugriff auf ihr eigenes Data Mart bzw. die für ihre Entscheidung benötigten Daten. Dies entspricht nur einem spezifischen Ausschnitt der Gesamtdaten, wie sie in einem DWH gespeichert werden. Bei einem DWH können die Anwender flexibel auf die Daten zur Analyse zugreifen. Dies kann lediglich durch vom Unternehmen festgelegte Rechte, die der Sicherheit dienen, eingeschränkt werden.

Letztlich unterscheiden sich Data Marts und zentrale DWHs in ihrer betriebswirtschaftlichen Zielsetzung. Data Marts dienen der effizienten Unterstützung der jeweiligen Anwender, wohingegen DWH die obere Managementebene effizient unterstützen sollen.

Die erläuterten Merkmalsausprägungen von Data Marts und DWH lassen sich zusammenfassend Tab. 1 entnehmen.

Tab. 1: Eigenschaften von Data Marts und Data Warehouses

Eigenschaft	Data Mart	Data Warehouse
Adressat der Datenbereitstellung	Abteilung	Unternehmen
Anzahl	Mehrere – viele	Eins – sehr wenige
Detaillierungsgrad der Daten	Zumeist höher aggregierte Daten	Kleinster Grad der Detaillierung
Datenmenge	Niedrig	Hoch
Menge historischer Daten	Niedrig	Hoch
Einfluss von externen Datenquellen	Zumeist nicht gegeben, wenn ja, dann nur spezifischer Ausschnitt	Hoch; sämtliche verfügbare, externe Datenquellen werden integriert, um die Qualität der Analysen verbessern zu können
Direkter Zugriff durch Endanwender	In der Regel möglich	Häufig nicht erlaubt; zentraler Betrieb des zentralen DWH durch IT-Abteilung; dient als Quelldatensystem für (abhängige) Data Marts
Modellierungskonventionen	Heterogen (proprietäre Data Marts, jede Abteilung hat ihre eigenen Konventionen); Einheitlich (abgeleitete Data Marts, Konventionen des zentralen DWH werden übernommen)	Einheitlich
Freiheitsgrad der Analysen	Eher gering (Anwender kann über die Abteilungsgrenzen nicht hinaussehen)	Flexibel; sämtliche zugänglichen Informationen können in Analysen einfließen
Betriebswirtschaftliches Ziel	Effiziente Unterstützung der Entscheider einer Abteilung, ausgerichtet alleinig auf deren Analyseanforderungen	Effiziente Managementunterstützung durch strategische, taktische und operative Informationsobjekte für alle Entscheider in einem Unternehmen

Quelle: in Anlehnung an (Schmidt-Volkmar, 2008) und (Kemper, Baars, & Mehanna, 2010).

Je nach Unternehmen und Anforderungen der einzelnen Abteilungen können Data Marts verschiedene Vor- und Nachteile aufweisen. Ein genereller Vorteil ist, dass die jeweiligen Abteilungen autonom auf die benötigten Daten zugreifen können. Dies führt zu einer hohen Flexibilität der

Abteilungen. Dadurch, dass die Abteilungen lediglich Zugriff auf einen Ausschnitt aller Daten haben, sind geringere Rechnerleistungen erforderlich, was zu geringeren Anschaffungs- und Betriebskosten führt (Holthuis, Der Aufbau von Data Warehouse-Systemen: Konzeption - Datenmodellierung - Vorgehen, 2001). Durch den autonomen Betrieb und die Pflege der jeweiligen Abteilungen können die Datenmodelle und Datenbestände an die jeweiligen fachlichen, organisatorischen und technischen Gegebenheiten der Abteilungen angepasst werden. Des Weiteren führt der relativ kleine Fokus auf meistens nur eine Abteilung dazu, dass das benötigte Datenvolumen relativ gering ist (Farkisch, 2011). Dies ergibt sich, weil eine starke Orientierung an den jeweiligen Fragestellungen und Entscheidungsproblemen (der einen Abteilung) erfolgen kann. Dadurch ergibt sich eine vereinfachte Wartung für die Abteilungen und schnellere Zugriffszeiten. Alle genannten Vorteile führen dazu, dass Data Marts meist schnell und auch relativ kostengünstig angelegt werden können (Schmidt-Volkmar, 2008). Beim Anlegen bzw. Entwickeln eines Data Marts können zudem die Anforderungen der Abteilungen berücksichtigt werden, sodass hinsichtlich der Antwortzeit und Abfragefreundlichkeit das Data Mart optimiert werden kann (Hiestermann, 2008).

Jedoch existieren für Unternehmen auch zahlreiche Nachteile, wenn sie sich für Data Marts entscheiden. Insbesondere wirkt sich die Haltung vieler Data Marts negativ auf die Effizienz aus. So müssen sämtliche Qualitätssicherungs-, Konsolidierungs- sowie Historisierungsmaßnahmen für jedes einzelne Data Mart durchgeführt werden (Hiestermann, 2008). Ein weiterer Nachteil ist, dass, wenn viele Anwender in unterschiedlichen Data Marts mit den Daten arbeiten, die Daten redundant an verschiedenen Orten abgespeichert werden. Zudem führt dies auch zu einer höheren Netzbelastung, da mehrere Anwender gleichzeitig die Daten aus den Data Marts abrufen (Holthuis, Der Aufbau von Data Warehouse-Systemen: Konzeption - Datenmodellierung - Vorgehen, 2001). Ein letzter zentraler Nachteil von Data Marts ist, dass es lediglich eine beschränkte Sicht auf die Daten gibt. So kann in den einzelnen Data Marts keine unternehmensweite Sicht auf die Daten erfolgen. Folglich ist es nur schwierig möglich, abteilungsübergreifende Analysen durchzuführen (Farkisch, 2011).

4 Online Analytical Processing (OLAP)

Analysekomponenten stellen einen weiteren Bereich im DWH-System dar. Dabei sind insbesondere OLAP-Systeme elementar. OLAP-Systeme dienen der Entscheidungsunterstützung des Managements, indem relevante Daten strukturiert und fokussiert dargestellt werden. Unternehmen müssen bei ihren Entscheidungen häufig multidimensionale Daten berücksichtigen. Steht beispielsweise die Entscheidung über die Eröffnung eines neuen Standorts an, so möchte der Entscheider Informationen über die Verkaufszahlen einer bestimmten Region in einem bestimmten Zeitraum vorliegen haben. Um diese Anforderung zu erfüllen, wird OLAP verwendet. Generell kann OLAP als ein Analyseinstrument definiert werden, durch das multidimensionale Datenauswertungen und -analysen ermöglicht werden. Nach Gluchowski/Dittmar/Gabriel kann OLAP definiert werden als „eine Software-Technologie, die Managern wie auch qualifizierten Mitarbeitern aus den Fachabteilungen schnelle, interaktive und vielfältige Zugriffe auf relevante und konsistente Informationen ermöglichen sollen. Im Vordergrund stehen dabei dynamische und multidimensionale Analysen auf historischen, konsolidierten Datenbeständen“ (Gluchowski, Dittmar, & Gabriel, 2008). Ursprünglich wurde OLAP von Codd et al. 1993 entwickelt.

OLAP wird klassischerweise durch einen Würfel dargestellt. Anhand des Würfels lassen sich gut die multidimensionalen Analysemöglichkeiten von OLAP erläutern.




Abb.10: Der OLAP-Würfel

Je nachdem, welche Ziele mit der Analyse verfolgt werden, lassen sich unterschiedliche Daten verwenden. So ist es beispielsweise möglich, dass nur eine bestimmte Region in den Fokus der Analyse gerät. Möglicherweise soll dabei nur eine bestimmte Kundengruppierung berücksichtigt werden. Des Weiteren soll nur eine bestimmte Produktgruppe, beispielsweise Getränke, betrachtet werden. So lässt sich z. B. der Umsatz von Getränken in den verschiedenen Regionen, in denen ein Unternehmen agiert, vergleichen. Durch die Struktur des OLAP-Würfels ist eine multidimensionale Datenanalyse gewährleistet.

Der OLAP-Würfel findet in der Praxis jedoch wenig Anwendung, da dieser die Anzahl der betrachteten Dimensionen auf drei beschränkt. Eine weitere Möglichkeit bieten Pivottabellen (s. Abschnitt 34.3, Abb. 14). Neben den Pivottabellen geben Rechenschiebermodelle einen guten Überblick über die verschiedenen Dimensionen und Ausprägungen. Rechenschiebermodelle verdeutlichen, welche Dimensionen existieren und inwiefern diese Dimensionen hierarchisch unterteilt werden. Abb.11 zeigt exemplarisch ein solches Rechenschiebermodell.




Abb.11: Rechenschiebermodell

Quelle: in Anlehnung an Kendzia 2010, S. 65.

Die erste Spalte gibt die verschiedenen Dimensionen an. Die Dimensionen haben unterschiedliche Ausprägungen, die hierarchisch den Dimensionen untergeordnet werden. Dabei kann es mehr als eine weitere Hierarchieebene geben. Die Zusammenhänge der Hierarchien sind durch Pfeile gekennzeichnet. So gehört der Ort Hagen zu NRW, was wiederum in Deutschland liegt. Der rote Rahmen gibt die aktuell betrachtete Kombination der Dimensionen an. So wird in der aktuellen Analyse lediglich der Umsatz von Bekleidung im ersten Quartal des Jahres 2010 in NRW betrachtet. Durch Verschiebung einzelner Dimensionen kann sich der Analysefokus verändern. Das Rechenschiebermodell soll verdeutlichen, welche Kombinationsmöglichkeiten für eine Analyse existieren und soll allgemein eine Übersicht über die verschiedenen Dimensionen und ihre Ausprägungen geben.

4.1 Anforderungen

Eigenschaften von OLAP

Die Abkürzung OLAP steht für Online Analytical Processing. Die Abkürzung verdeutlicht bereits die wesentlichen Eigenschaften von OLAP. Online bedeutet, dass Anwender direkt auf den zentralen Datenbestand zugreifen können, um Daten zu betrachten oder zu manipulieren. Die Eigenschaft Analytical steht dafür, dass unterschiedliche Sichten für die Entscheidungsträger von Bedeutung sind und nicht, wie beim Online Transactional Processing (OLTP) die verschiedenen Geschäftsvorfälle. Processing steht für die Eigenschaft, dass schnelle Berechnungen und Manipulationen durch den Anwender durchgeführt werden können (Goeken, 2006).

Neben den zentralen Eigenschaften von OLAP hat *Codd* zwölf Regeln aufgestellt, die durch OLAP abgedeckt werden sollen. Diese Regeln beinhalten Anforderungen, aber auch Fachkonzepte und die technische Realisierung (Goeken, 2006). Da *Codd* jedoch der Begründer von OLAP ist, sollten die zwölf Regeln an dieser Stelle nicht fehlen.

Die zwölf Regeln nach Codd (Codd, Codd, & Salley, 1993) werden im Folgenden kurz erläutert.

Zwölf Regeln nach Codd

1. Multidimensionale konzeptionelle Sichtweise auf die Daten: Das wesentliche Merkmal von OLAP ist die multidimensionale Sichtweise auf die Daten. Dadurch wird es dem Entscheider ermöglicht, die erforderlichen Daten zu analysieren, aggregieren oder miteinander korrelieren. Durch verschiedene Operationen, die OLAP zur Verfügung stellt, ist es dem Entscheider möglich, diese relativ einfach und ohne großen Aufwand durchzuführen und so die gewünschten Analyseergebnisse zu erzielen. Am Ende der Analyse stellt OLAP die Ergebnisse visualisiert zur Verfügung, sodass die Interpretation dieser für den Entscheider einfach ist.
2. Transparenz: Die Transparenz ist eine wichtige Eigenschaft, die es Entscheidern ermöglicht, auch ohne Kenntnisse der zugrundeliegenden Datenstrukturen die gewünschten Abfragen durchzuführen.
3. Zugriffsmöglichkeit: Dem Entscheider muss es möglich sein, seine Analysen auf Basis unternehmensinterner und unternehmensexterner Datenquellen durchzuführen. Alle vom Entscheider benötigten Daten müssen im DWH vorgehalten werden.
4. Gleichbleibende Antwortzeit bei der Berichterstellung: Unabhängig davon, welche Daten der Entscheider zur Analyse benötigt, muss die Antwortzeit, die für die Erstellung des Berichts benötigt wird, konstant sein. So darf diese Zeit beispielsweise nicht von der Anzahl der Dimensionen oder der Anzahl der Datensätze abhängen. Die Leistungsfähigkeit von OLAP sollte folglich immer konstant bleiben.
5. Client-Server-Architektur: Zur Realisierung von OLAP sollte eine Client-Server-Architektur verwendet werden.¹ Nur so kann die Speicherung, Verarbeitung und Darstellung getrennt werden. Hierzu sollte der OLAP-Server eine offene Schnittstelle zur Verfügung stellen, damit Entscheider mit verschiedenen Anwendungen darauf zugreifen können (Bauer & Günzel, 2001).
6. Generische Dimensionalität: Alle Dimensionen sollten in ihrer Struktur sowie ihrer Funktionalität einheitlich gestaltet sein. Keine Dimension sollte im Vorfeld bereits vorgelegt sein, sodass alle Dimensionen symmetrisch sind und somit individuell untereinander ausgetauscht werden können.
7. Dynamische Behandlung unvollständig besetzter Matrizen: Unvollständig besetzte Matrizen entstehen dann, wenn bei der Kombination von mehreren Dimensionen keine Werte existieren. Dennoch sollten die Funktionalitäten von OLAP nicht eingeschränkt werden.
8. Mehrbenutzerunterstützung: Es muss möglich sein, dass mehrere Benutzer parallel auf die gleichen Daten zugreifen und diese für ihre Analysen verwenden können. Dabei ist insbesondere sicherzustellen, dass die Konsistenz der Daten beibehalten wird. Generell muss über eine Rechteverwaltung innerhalb des Unternehmens festgelegt werden, welche Personen Lese- sowie Schreibrechte haben.
9. Uneingeschränkte kreuzdimensionale Operationen: Es muss möglich sein, dass ein Anwender alle Berechnungen, die er zur Entscheidungsunterstützung benötigt, durchführen kann. Dabei soll dies unabhängig von den benötigten Dimensionen sowie über beliebige Dimensionen hinweg erfolgen können. Das System muss offen sein für jegliche Abfragen des Anwenders.
10. Intuitive Darstellung und Bearbeitung der Daten: Dem Anwender muss es intuitiv möglich sein, die von ihm gewünschten Analysen selbstständig und ohne größere Kenntnisse des Systems

¹ Zur ausführlichen Erläuterung siehe Gehring/Pankratz 2006: Grundzüge der Wirtschaftsinformatik, Einheit 1 „Technologische Grundlagen der Informationsverarbeitung“.

durchzuführen. Dies betrifft insbesondere die Navigation durch die Daten.

11. Flexible Berichterstellung: Es müssen flexibel Berichte erstellt werden können, d. h. es muss möglich sein, die Anordnungen flexibel zu generieren. Die Berichtselemente aus verschiedenen Zeilen und Spalten müssen frei positionierbar sein.
12. Unbegrenzte Anzahl von Dimensionen und Klassifikationsebenen: Für die Analyse sollte eine beliebige Anzahl an Dimensionen genutzt werden könne. Erfahrungen aus der Praxis zeigen jedoch, dass für eine Analyse meistens zwischen fünf und acht Dimensionen verwendet werden. Daher reicht es aus, wenn 15-20 Dimensionen für eine Analyse gleichzeitig hinzugezogen werden können. Dies sollte zur Unterstützung der meisten Entscheidungen ausreichend sein.

Diese zwölf Regeln von Codd werden vielfach in der Literatur kritisch diskutiert. Einige der Regeln gelten als veraltet bzw. nicht mehr sinnvoll. Dies trifft z. B. auf die sechste Regel: generische Dimensionalität zu. So kann es sinnvoll sein, wenn Dimensionen, die eine bestimmte Semantik erfordern wie z. B. die Zeit, vorbelegt sind (Bauer & Günzel, 2001). Auch *Codd* selber hat seine aufgestellten Regeln nur zwei Jahre später durch sechs zusätzliche Regeln erweitert. Diese werden im Folgenden kurz erläutert.

Erweiterung der zwölf Regeln

1. Datenintegration: Anwender sollen einerseits auf die von OLAP eigene multidimensionale Datenstruktur zugreifen können, andererseits aber auch auf weitere darunter liegende Daten.
2. Unterstützung verschiedener Analysemodelle: OLAP soll vier verschiedene Datenmodelle unterstützen. Diese sind das kategorische, das exegetische, das kontemplative sowie das formelbasierte Datenmodell. Beim kategorischen Datenmodell werden historische Daten mit den aktuellen Daten verglichen, um so den aktuellen Zustand zu definieren. Beim exegetischen Datenmodell werden die Ursachen, die zu dem aktuellen Zustand geführt haben, ermittelt. Das kontemplative Modell führt eine Simulation mit verschiedenen Werten oder Abweichungen von Dimensionen oder zwischen Dimensionen durch. Beim formelbasierten Modell sind ein vorgegebener sowie ein angestrebter Zielzustand definiert. Es wird berechnet, durch welche Veränderungen von Kennzahlen und Parametern der Zielzustand erreicht werden kann (Bauer & Günzel, 2001).
3. Trennung analyseorientierter von den operativen Daten: Wenn Daten im DWH verändert werden, so dürfen diese Veränderungen nicht ins Quellsystem übernommen werden.
4. Trennung der Speicherorte: Gemäß der achten Regel haben verschiedene Anwender ein Schreibrecht. Die Veränderungen dürfen jedoch nicht auf dem produktiven Datenbestand gespeichert werden, sondern müssen an einem anderen Ort gespeichert werden.
5. Unterscheidung zwischen Null- und Fehlwerten: Es müssen fehlende Werte und Werte mit dem numerischen Wert 0 unterschieden werden können.
6. Behandlung von fehlenden Werten: Fehlende Werte sollen effizient verwaltet werden, sodass eine optimale Nutzung der Speicherkapazität gewährleistet werden kann.

Einen anderen Versuch, OLAP zu charakterisieren, haben *Pendse* und *Creeth* 1995 unternommen. Sie charakterisieren OLAP mit den Begriffen Geschwindigkeit, Analysemöglichkeit, Sicherheit, Multidimensionalität sowie Kapazität (englisch „fast analysis of shared multidimensional information“, kurz FASMI). Die fünf Eigenschaften werden im Folgenden kurz erläutert (vgl. im Folgenden (Bauer & Günzel, 2001)).

- **Geschwindigkeit:** Anfragen von Anwendern sollen in unter fünf Sekunden beantwortet werden. Die Antwortzeit hängt von der Anfrage ab. Besonders häufige Anfragen werden schneller beantwortet, komplexere Anfragen dauern häufig länger als fünf Sekunden. **FASMI**
- **Analysemöglichkeit:** OLAP soll eine intuitive, benutzerfreundliche Analyse der Daten ermöglichen. Hierzu zählt, dass der Anwender einfache Funktionen nutzen kann, sodass er entsprechend seinen eigenen Anforderungen Berechnungen erstellen und Analysen durchführen kann. Dabei ist es unerheblich, ob diese Funktionen über ein externes Werkzeug eingebunden werden oder ob OLAP diese selber zur Verfügung stellt.
- **Sicherheit:** Der Aspekt Sicherheit bezieht sich auf die Sicherstellung, dass mehrere Anwender gleichzeitig auf ein und dieselben Daten zugreifen können.
- **Multidimensionalität:** OLAP zeichnet sich vor allem durch seine Multidimensionalität aus. Der Anwender kann multidimensionale Daten für seine Analysezwecke nutzen und vor allem mehrere Dimensionen nach seinen Bedürfnissen miteinander verbinden und Berechnungen und Analysen durchführen.
- **Kapazität:** OLAP verwendet häufig eine sehr große Datenmenge zur Analyse. Es wird gleichzeitig jedoch auch gefordert, dass, unabhängig von der Anzahl der Anfragen und der involvierten Datenmenge, die Antwortzeiten stabil bleiben.

4.2 Ausprägungen

Neben dem klassischen OLAP sind in der Literatur häufig weitere OLAP-Ausprägungen zu finden. Die am weitesten verbreiteten Ausprägungen werden im Folgenden kurz erläutert.

Die beiden häufigsten Ausprägungen von OLAP sind das multidimensional OLAP (MOLAP) sowie das relational OLAP (ROLAP). ROLAP basiert auf relationalen Datenbankmanagementsystemen (DBMS). Diese werden normalerweise nach dem Star-Schema oder nach dem Snowflake-Schema implementiert (Humm & Wietek, 2005). Dabei werden multidimensionale Datenmodelle in Tabellen abgespeichert, ohne dass Informationen verloren gehen. Es gibt dabei zwei verschiedene Tabellenarten: Dimensionstabellen und Faktentabellen. Die Dimensionstabellen werden grafisch häufig sternförmig um die Faktentabellen verteilt, sodass sich dadurch der Name Star-Schema erklären lässt. Abb.12 zeigt ein beispielhaftes Star-Schema. **ROLAP**




Abb.12: Beispielhaftes Star-Schema

Quelle: entnommen aus (Farkisch, 2011), S. 29.

In der Mitte der Abbildung 12 ist die Faktentabelle. Die Schlüssel einer Faktentabelle weisen auf die entsprechenden Dimensionstabellen. Die Schlüssel in der Abbildung 12 sind Ort_ID, Produkt_ID, Zeit_ID und Kunden_ID. Die Stammdaten werden in den Dimensionstabellen gehalten. In den Faktentabellen sind die Bewegungsdaten, die durch die Stammdaten beschrieben werden. So wird beispielsweise die Produkt_ID durch Eigenschaften wie die Artikelnummer, die Produktgruppe oder die Produktfamilie charakterisiert (Hahne, 2003).

MOLAP

ROLAP-Anwendungen erzeugen die multidimensionalen Sichten dynamisch und nicht wie MOLAP physisch. Bei MOLAP-Anwendungen werden die Daten tatsächlich physisch in mehrdimensionalen Datenbanken gespeichert (Goeken, 2006). Dies führt dazu, dass das Antwortverhalten in der Regel schneller ist. Jedoch hat die Verwendung von MOLAP den Nachteil, dass häufig ein höheres Datenvolumen vorgehalten wird. Je höher die Anzahl der Dimensionen ist, desto höher ist auch das Datenvolumen. Zudem sind MOLAP-Anwendungen häufig nicht so flexibel zu verwenden, da die Anzahl der Dimensionen, die verwendet werden kann, begrenzt ist (Goeken, 2006). Diese Nachteile führen dazu, dass MOLAP nur für diejenigen Unternehmen empfehlenswert ist, die für ihre Analysen nur kleinere Datenmengen verwenden wollen (Farkisch, 2011).

ROLAP vs. MOLAP

ROLAP hat gegenüber MOLAP den Vorteil, dass große Datenvolumina besser verwaltet werden können. Zudem kann die Anzahl der Dimensionen bei der Anwendung von ROLAP flexibel gewählt werden. Ein weiterer Vorteil von ROLAP gegenüber MOLAP ist, dass in den meisten Unternehmen Know-How über die Verwendung von ROLAP-Anwendungen vorhanden ist. Dem gegenüber fehlt in vielen Unternehmen das Know-How über die Verwendung von MOLAP-Anwendungen. ROLAP basiert auf einer robusten Technologie, die in den meisten Unternehmen verfügbar ist. Der letzte wesentliche Vorteil von ROLAP ist, dass

keine Vorberechnungen notwendig sind, da die ROLAP-Anwendung auf bestehende relationale Tabellen zugreift, wohingegen der Vorberechnungsaufwand von MOLAP-Anwendungen sehr hoch ist (Goeken, 2006). Eine Mischung aus ROLAP und MOLAP stellt das hybrid OLAP (HOLAP) dar. Beim HOLAP wird versucht, die Vorteile von MOLAP und ROLAP miteinander zu kombinieren und somit die Nachteile zu eliminieren (Humm & Wietek, 2005).

Eine weitere Ausprägung von OLAP stellt das sogenannte OLTP dar. OLTP unterstützt das operative Geschäft eines Unternehmens im Gegensatz zu OLAP, das die Analyse von Entscheidungen unterstützt. Im Gegensatz zu OLAP werden beim OLTP sehr aktuelle und detaillierte Daten verwendet, wohingegen die Daten, die zur OLAP-Analyse verwendet werden, meist historisch und aggregiert sind. Zudem unterscheiden sich OLAP und OLTP auch in den möglichen Operationen. Während beim OLAP multidimensionale Abfragen wie ad hoc-Abfragen durchgeführt werden, werden beim OLTP vorrangig Operationen wie das Anlegen, Lesen, Ändern und Löschen von Daten verwendet (Humm & Wietek, 2005).

OLTP

4.3 Operationen in OLAP

Die multidimensionale Analyse der Daten lässt sich in verschiedene Analyseklassen einteilen. Je nach Zielsetzung müssen die Daten beispielsweise anders miteinander kombiniert werden, weiter gefiltert werden oder auch stärker aggregiert werden. Im Folgenden werden die wesentlichen Operationen in einem OLAP-Würfel vorgestellt (vgl. hier und im Folgenden (Kemper, Baars, & Mehanna, 2010)).

Pivotierung/ Rotation

Pivotierung

Bei der Pivotierung oder Rotation wird der OLAP-Würfel um seine Achse gedreht. Dies kann sowohl die horizontale als auch die vertikale Achse sein. Das Ziel der Rotation ist es, die betrachteten Dimensionen gegeneinander auszutauschen um so eine weitere Analyse durchzuführen. In Abb.13 werden im linken OLAP-Würfel die beiden Dimensionen auf der Ordinate und Abszisse, Kunde und Produkte, zur Analyse verwendet. Um nun eine andere Kombination der Dimensionen betrachten zu können, muss der Würfel gedreht werden. In der Abbildung 13 erfolgt die Rotation um die waagerechte Achse. Folglich werden die beiden Dimensionen Kunde und Region ausgetauscht. Nach der Rotation kann der Anwender nun die beiden Dimensionen Produkte und Region analysieren.




Abb.13: Die OLAP-Operation Pivotisierung/Rotation

Quelle: eigene Darstellung

Der Begriff Pivotierung als Synonym für die Rotation hat sich vor allem daraus ergeben, dass in der Realität häufig mehr als drei Dimensionen existieren. In einem Würfel lassen sich jedoch nur drei Dimensionen abbilden. Daher erfolgt die Darstellung der Dimensionen in der Realität zumeist nicht mit Hilfe der charakteristischen OLAP-Würfel, sondern über Tabellen. Um eine Rotation in einer Tabelle darzustellen, wird häufig eine Pivottabelle genutzt. Die linke Tabelle in Abb. 14 beinhaltet die zur Analyse zur Verfügung stehenden Daten. Die rechte Tabelle zeigt die eigentliche Pivottabelle. Der Anwender kann die Daten, die er analysieren möchte, in den Zeilen oder Spalten der Tabelle anzeigen lassen. So kann der Anwender mehrere Dimensionen in die Tabelle aufnehmen. In der aktuellen Tabelle werden die Quartalsergebnisse je Filiale sowie je Artikel ausgegeben. Eine Rotation führt dazu, dass neue Dimensionen in die Tabelle aufgenommen werden. So könnte beispielsweise zusätzlich neben dem Gewinn der Umsatz betrachtet werden.

Filialen	Quartal	Artikel	Umsatz	Gewinn
Dortmund	I.Qua.	Getränke	2.728,80 €	791,35 €
Hamburg	I.Qua.	Getränke	2.956,20 €	857,30 €
Essen	IV.Qua.	Lebensmittel	1.587,50 €	952,50 €
Dortmund	IV.Qua.	Drogerieartikel	3.155,20 €	1.009,66 €
Essen	I.Qua.	Lebensmittel	1.725,00 €	1.035,00 €
Dortmund	IV.Qua.	Lebensmittel	1.775,00 €	1.065,00 €
Köln	IV.Qua.	Lebensmittel	1.837,50 €	1.102,50 €
Bremen	I.Qua.	Getränke	3.941,60 €	1.143,06 €
Hamburg	III.Qua.	Drogerieartikel	3.648,20 €	1.167,42 €
Frankfurt	IV.Qua.	Elektroartikel	3.600,00 €	1.260,00 €
Essen	II.Qua.	Elektroartikel	4.050,00 €	1.417,50 €
Dortmund	II.Qua.	Drogerieartikel	4.437,00 €	1.419,84 €
Hamburg	I.Qua.	Drogerieartikel	5.225,80 €	1.672,26 €
Köln	II.Qua.	Drogerieartikel	5.620,20 €	1.798,46 €
Bremen	IV.Qua.	Drogerieartikel	6.606,20 €	2.113,98 €
Hamburg	III.Qua.	Elektroartikel	6.975,00 €	2.441,25 €
Frankfurt	III.Qua.	Elektroartikel	7.650,00 €	2.677,50 €
Essen	IV.Qua.	Bekleidung	986,00 €	640,90 €
Dortmund	II.Qua.	Bekleidung	1.079,50 €	701,68 €
Essen	III.Qua.	Lebensmittel	1.512,50 €	907,50 €
Frankfurt	I.Qua.	Lebensmittel	1.675,00 €	1.005,00 €
Dortmund	I.Qua.	Lebensmittel	1.750,00 €	1.050,00 €
Hamburg	IV.Qua.	Elektroartikel	3.375,00 €	1.181,25 €
Essen	IV.Qua.	Drogerieartikel	6.507,60 €	2.082,43 €
Köln	II.Qua.	Elektroartikel	6.525,00 €	2.283,75 €
Bremen	I.Qua.	Elektroartikel	6.525,00 €	2.283,75 €
Dortmund	IV.Qua.	Bekleidung	935,00 €	607,75 €
Köln	II.Qua.	Bekleidung	977,50 €	635,38 €
Bremen	II.Qua.	Bekleidung	977,50 €	635,38 €
Hamburg	I.Qua.	Bekleidung	986,00 €	640,90 €
Essen	I.Qua.	Bekleidung	1.198,50 €	779,03 €
Dortmund	III.Qua.	Lebensmittel	1.462,50 €	877,50 €
Köln	II.Qua.	Getränke	3.107,80 €	901,26 €
Frankfurt	I.Qua.	Getränke	3.107,80 €	901,26 €

Artikel	Filialen	I.Qua.	II.Qua.	III.Qua.	IV.Qua.	Gesamtergebnis
Bekleidung	Bremen	690,625	635,375	613,275	751,4	2690,675
	Dortmund	823,225	701,675	762,45	607,75	2895,1
	Essen	779,025	740,35	718,25	640,9	2878,525
	Frankfurt	690,625	663	668,525	624,325	2646,475
	Hamburg	640,9	767,975	723,775	767,975	2900,625
	Köln	712,725	635,375	756,925	817,7	2922,725
Bekleidung Ergebnis		4337,125	4143,75	4243,2	4210,05	16934,125
Drogerieartikel	Bremen	1167,424	1672,256	1514,496	2113,984	6468,16
	Dortmund	2113,984	1419,84	1640,704	1009,664	6184,192
	Essen	2113,984	1482,944	2113,984	2082,432	7793,344
	Frankfurt	1072,768	1041,216	1640,704	1672,256	5426,944
	Hamburg	1672,256	946,56	1167,424	2208,64	5994,88
	Köln	1009,664	1798,464	1672,256	1356,736	5837,12
Drogerieartikel Ergebnis		9150,08	8361,28	9749,568	10443,712	37704,64
Elektroartikel	Bremen	2283,75	2401,875	1850,625	2677,5	9213,75
	Dortmund	2401,875	2362,5	2244,375	2520	9528,75
	Essen	1260	1417,5	1653,75	1890	6221,25
	Frankfurt	2362,5	2480,625	2677,5	1260	8780,625
	Hamburg	1693,125	1299,375	2441,25	1181,25	6615
	Köln	2244,375	2283,75	2008,125	1850,625	8386,875
Elektroartikel Ergebnis		12245,625	12245,625	12875,625	11379,375	48746,25
Getränke	Bremen	1143,064	1077,118	989,19	1252,974	4462,346
	Dortmund	791,352	1209,01	1230,992	1472,794	4704,148
	Essen	1296,938	989,19	1099,1	1406,848	4792,076
	Frankfurt	901,262	791,352	989,19	1472,794	4154,598
	Hamburg	857,298	879,28	1340,902	681,442	3758,922
	Köln	1077,118	901,262	1055,136	1230,992	4264,508
Getränke Ergebnis		6067,032	5847,212	6704,51	7517,844	26136,598
Lebensmittel		5775	6007,5	5325	6052,5	23160
Gesamtergebnis		37574,862	36605,367	38897,903	39603,481	152681,613

Abb. 14: Pivottabelle

Quelle: eigene Darstellung

Roll-Up & Drill-Down

Roll-Up & Drill-Down

Beim Roll-Up und Drill-Down wird die Hierarchieebene einer Dimension verändert. Um eine gute Übersicht zu erhalten, werden die Daten bei OLAP häufig in aggregierter Form ausgegeben. So können Regionen beispielsweise zusammengefasst werden in die Region NRW, Bayern, Sachsen usw., aber die Regionen können auch stärker aggregiert werden, wenn die Daten bundeslandübergreifend zusammengefasst werden, beispielsweise in Deutschland, Frankreich, Niederlande usw. Das stärkere Zusammenfassen von Daten wird als Roll-Up bezeichnet. Wenn Daten weiter eine Hierarchieebene tiefer aggregiert werden, so handelt es sich um Drill-Down. Abb. 15 zeigt die beiden Operationen grafisch. In der Abbildung 15 sollen die beiden Operationen auf die Dimension Produkte angewendet werden. Im linken OLAP-Würfel sind die einzelnen Produkte sehr stark aggregiert. So finden sich dort die Produkte Getränke, Lebensmittel, Bekleidung, Drogerieartikel sowie Elektroartikel. Im rechten OLAP-Würfel wurde eine dieser Produkte, die Lebensmittel, weiter exemplarisch disaggregiert in Gemüse, Fleisch, Konserven, Brot und Süßwaren. Die Operation vom linken zum rechten OLAP-Würfel wird als Drill-

Down bezeichnet, die Operation von rechts nach links als Roll-Up. Beispielsweise kann es für einen Supermarkt wichtig sein, die aggregierten Daten (linker OLAP-Würfel) zu analysieren, um z. B. darüber zu entscheiden, ob den Lebensmitteln im Supermarkt mehr Regalgänge zur Verfügung gestellt werden. Andererseits kann aber auch die Betrachtung einzelner Produkte sinnvoll sein, um z. B. eine Entscheidung darüber zu treffen, ob dieses Produkt aus dem Sortiment genommen werden soll. Diese beiden Beispiele machen deutlich, dass die durchzuführende Operation erheblich von dem Ziel der Analyse abhängt.




Abb. 15: Die OLAP-Operationen Roll-Up und Drill-Down

Quelle: eigene Darstellung

Slice & Dice

Die Operationen Slice und Dice filtern die Gesamtdatenmenge. Slice bedeutet aus dem Englischen übersetzt Scheibe oder Schnitt und kann so interpretiert werden, dass lediglich eine Scheibe aus dem Gesamtwürfel betrachtet wird. (s. Abb. 16). Beim Slice wird eine Dimension auf einen einzigen Wert reduziert (z. B. wird nur eine Region oder nur ein Produkt betrachtet), bei allen anderen Dimensionen werden alle Werte berücksichtigt. In der Abbildung 16 werden alle drei Dimensionen in die Analyse einbezogen. Es wird jedoch lediglich eine Region betrachtet, wobei alle verfügbaren Produkte sowie alle Kunden berücksichtigt werden. Wenn die ausgewählten Scheiben nacheinander verändert werden, so können die Umsätze aller verschiedenen Produkte miteinander verglichen werden. Wenn beispielsweise nur eine Region berücksichtigt wird, so können die Umsätze verschiedener Regionen miteinander in Bezug gesetzt werden.

Slice & Dice




Abb. 16: Die OLAP-Operation Slice

Quelle: eigene Darstellung

Beim Dice werden die verfügbaren Daten zwar ebenso wie beim Slice gefiltert, jedoch erfolgt dies nicht in Form der soeben beschriebenen Scheiben. Vielmehr kann der Anwender einzelne Blöcke des Gesamtwürfels auswählen und für seine Analysezwecke verwenden. Der Anwender fokussiert lediglich einen Teilausschnitt aus der Realität. In Abb. 17 werden beispielsweise die Daten von zwei Produkten, zwei Regionen sowie zwei Kunden berücksichtigt. Somit ist das Ergebnis dieser Operation ein eigener, neu entstandener Datenwürfel.




Abb. 17: Die OLAP-Operation Dice

Quelle: eigene Darstellung

4.4 Zusammenfassung der Operationen in OLAP

Zum besseren Verständnis der OLAP-Operationen werden diese zum Abschluss des Kapitels anhand eines weiteren Beispiels kurz zusammengefasst. Die Ausgangslage ist in der Abbildung 18 dargestellt.




Abb. 18: OLAP-Würfel

Auf der x-Achse ist die Dimension „Produktlinie“ abgebildet, die y-Achse bildet die Dimension „Region“ ab und die z-Achse wird durch die Dimension „Periode“ belegt. Wie bereits beschrieben, werden in der Realität aufgrund einer normalerweise größeren Anzahl an Dimensionen Tabellen genutzt, da sich die OLAP-Würfel abbildungstechnisch nur für drei Dimensionen eignen.

Der Roll-Up, wie in der Abbildung 19 dargestellt, aggregiert Daten, indem eine Hierarchiestufe oder Dimension „nach oben steigt“. So wird im Beispiel „Stadt“ zu „Region“ und es können dann Analysen auf einer höher liegenden Hierarchieebene (hinsichtlich der Dimension Region) durchgeführt werden.




Abb. 19: OLAP-Operation: Roll-Up

Beim in der Abbildung 20 dargestellten Drill-Down erfolgt eine Detaillierung. Im Beispiel werden nun nicht mehr die Regionen, sondern wieder die Städte dargestellt.




Abb. 20: OLAP-Operation: Drill-Down

Beim in der Abbildung 21 dargestellten Slicing werden gleichmäßige Scheiben aus dem Würfel entlang einer (ggf. mehrerer) Dimensionen geschnitten. Aus der Dimension Periode wird im Beispiel der Monat Mai ausgewählt (ausgeschnitten), sodass für diesen Monat Analysen zu den Produktlinien und Regionen durchgeführt werden können.




Abb. 21: OLAP-Operation: Slicing

Das Dicing, dargestellt in der Abbildung 22, schneidet durch Drehen („würfeln“) und „Slicing“ einen Teilwürfel aus einem größeren Würfel heraus.

So werden im Beispiel nach der Operation Dicing statt der Produktlinien A, B, C und D auf der x-Achse nur noch die Produktlinien B und C auf der x-Achse dargestellt. Auch bei den Dimensionen „Region“ und „Periode“ könnten zusätzliche Einschränkungen vorgenommen werden. So würden dann z. B. zusätzlich nicht mehr alle Regionen auf der y-Achse dargestellt, sondern nur die von Interesse. Wie bei allen Operationen ist dies immer abhängig vom Analysezzweck.




Abb. 22: OLAP-Operation: Dicing

Die in der Abbildung 23 dargestellte Rotation (auch: Pivotisierung) bringt den Würfel in eine neue Position. Statt der Dimension „Region“ in der Ausgangslage des Beispiels soll nun die Dimension „Produktlinie“ im Hauptbetrachtungsbereich (x-Achse) positioniert werden. Die Datentiefe der Dimensionen ändert sich bei einer reinen Rotation nicht.




Abb. 23: OLAP-Operation: Rotation (Pivotierung)

5 Zusammenfassung

DWH-Systeme sind ein Erfolgsfaktor, um Informationen zur Entscheidungsunterstützung generieren zu können. Nur wenn ein DWH-System entsprechend in ein Unternehmen integriert werden kann, können die benötigten Informationen auch abgerufen werden. Eine Möglichkeit, Daten strukturiert und einfach zu Analysezwecken zu nutzen, bietet dabei OLAP, das eine Komponente im DWH-System darstellt. Es wurde gezeigt, dass Anwender mit Hilfe einfacher Operationen die für sie relevanten Daten nutzen können.

Doch nur wenn die Qualität der zu nutzenden Daten entsprechend hoch ist, können tatsächlich Informationen generiert werden. Dies zeigt, dass DWHs nicht losgelöst vom KDD-Prozess betrachtet werden können (vgl. Einheit 2). Aber auch sie bilden im Gegenzug eine wichtige Grundlage, um die in Einheit 2 vorgestellten Methoden und Instrumente im KDD-Prozess nutzen zu können.

**Rückblick
auf Einheit 2**

Die bisher vorgestellten Inhalte der Einheit 1-3 stellen jedoch nur die klassischen BI-Komponenten dar, die bereits in den Anfängen von BI entwickelt und diskutiert wurden. Das Themenfeld BI ist jedoch noch immer sehr aktuell ist und unterliegt ständigen Weiterentwicklungen, die in Einheit 4 thematisiert werden.

**Ausblick auf
Einheit 4**

6 Übungsaufgaben

1. Erläutern Sie die verschiedenen Typen von Business Rules!
2. Erläutern Sie, weshalb fachliche Metadaten häufig auch als unstrukturierte Metadaten bezeichnet werden!
3. Erläutern Sie die Bedeutung von Metadaten anhand des Beispiels der Datumsangabe 10/12/99!
4. Grenzen Sie dispositive und operative Daten voneinander ab!
5. Erläutern Sie die zentralen Eigenschaften eines DWH nach Inmon!
6. Nennen und erläutern Sie die drei Phasen im ETL-Prozess!
7. Welche verschiedenen Ebenen lassen sich in einem DWH-System unterscheiden? Erläutern Sie diese kurz!
8. Grenzen Sie Data Marts und DWHs voneinander ab!
9. Erläutern Sie die Eigenschaften online analytical und processing im Rahmen von OLAP!
10. Was besagt das Prinzip FASMI im Rahmen von OLAP?
11. Erläutern Sie die Funktionalität „Pivotierung“ im Rahmen von OLAP!

Literaturverzeichnis

- Apel, D., Behme, W., Eberlein, R., & Merighi, C. (2009). Datenqualität erfolgreich steuern - Praxislösungen für Business-Intelligence-Projekte. München u. a.: Hanser Verlag.
- Auth, G. (2003). Prozessorientierte Organisation des Metadatenmanagements für Data-Warehouse-Systeme. Bamberg: Universität St. Gallen.
- Bartel, W., Schwarz, S., & Strasser, G. (2000). Der ETL-Prozess des Data Warehousing. In R. Jung, & R. Winter, Data Warehouse Strategie (S. 43-60). Berlin u.a.: Springer.
- Bauer, A., & Günzel, H. (2001). Data Warehouse Systeme. Heidelberg: dpunkt-Verlag.
- Becker, D., & Proff, D. (2001). Data Warehousing: Ausgewählte Business Intelligence-Lösungen für die Versicherungswirtschaft. In W. Behme, & H. Muksch, Data Warehouse-gestützte Anwendungen (S. 249-280). Wiesbaden: Gabler.
- Behme, W., & Muksch, H. (2001). Data Warehouse-gestützte Anwendungen - Theorie und Praxiserfahrungen in verschiedenen Branchen. Wiesbaden: Gabler Verlag.
- Business Rules Group. (2003). Business Rules Manifest: Die Prinzipien der Business Rules Unabhängigkeit. Abgerufen am 29. 04 2011 von <http://www.businessrulesgroup.org/brmanifesto/BRManifestDeutsch.pdf>
- Business Rules Group. (2010). The Business Motivation Model - Business Governance in a Volatile World. Abgerufen am 20. 10 2011 von http://www.businessrulesgroup.org/second_paper/BRG-BMM.pdf
- Capgemini. (2009). IT-Trends. München.
- Codd, E., Codd, S., & Salley, C. (1993). Providing OLAP to User-Analysts: An IT Mandate. Ann Arbor/Michigan: Codd & Associates.
- Cordts, S., Blakowski, G., & Brosius, G. (2011). Datenbanken für Wirtschaftsinformatiker. Wiesbaden: Vieweg + Teubner Verlag.
- English, L. (1999). Improving Data Warehouse and Business Information Quality - Methods for Reducing Costs and Increasing Profits. New York: Wiley & Sons.
- Farkisch, K. (2011). Data Warehouse-Systeme kompakt - Aufbau, Architektur, Grundfunktionen. Heidelberg u.a.: Springer.
- Gluchowski, P., Dittmar, C., & Gabriel, R. (2008). Management Support Systeme und Business Intelligence. Berlin u.a.: Springer.
- Goeken, M. (2006). Entwicklung von Data-Warehouse-Systemen - Anforderungsmanagement, Modellierung, Implementierung. Wiesbaden: Deutscher Universitätsverlag.
- Gray, P., & Watson, H. (1998). Present and Future Directions in Data Warehousing. The DATA BASE for Advances in Information Systems(29), S. 83-90.
- Grob, L., Bensberg, F., & Coners, A. (4 2008). Regelbasierte Steuerung von Geschäftsprozessen - Konzeption eines Ansatzes auf Basis von Process Mining. Wirtschaftsinformatik, S. 268-

281.

- Hüner, K., Brauer, B., Otto, B., & Österle, H. (277. 48 2011). Fachliches Metadatenmanagement mit einem semantischen Wiki. HMD - Praxis der Wirtschaftsinformatik, S. 98-108.
- Hahne, M. (2003). Logische Datenmodellierung zur Abbildung mehrdimensionaler Datenstrukturen im SAP Business Information Warehouse. In G. Weikum, & H. R. Schöning, BTW 2003, Datenbanksysteme für Business, Technologie und Web., Tagungsband der 10. BTW-Konferenz, 26.-28. Februar 2003 (S. 630-647). Bon: Köllen Druck + Verlag.
- Hiestermann, D. (2008). Analytisches Customer Relationship Management - Konzeption und Realisierung auf Basis der Business-Intelligence-Instrumente Data Warehouse und Data-Mining. Dissertation. Technische Universität Dortmund.
- Holten, R., Knackstedt, R., & Becker, J. (2001). Betriebswirtschaftliche Herausforderungen durch Data-Warehouse-Technologien. In R. Schütte, T. Rotthowe, & R. Holten, Data-Warehouse-Managementhandbuch (S. 41-64). Berlin u.a.: Springer.
- Holthuis, J. (2001). Data-Warehousing im Pharma-Marketing. In W. Behme, & H. Muksch, Data Warehouse-gestützte Anwendungen - Theorie und Praxiserfahrungen in verschiedenen Branchen (S. 161-175). Wiesbaden: Gabler.
- Holthuis, J. (2001). Der Aufbau von Data Warehouse-Systemen: Konzeption - Datenmodellierung - Vorgehen. Wiesbaden: Gabler Vieweg Verlag.
- Humm, B., & Wietek, F. (1. 33 2005). Architektur von Data Warehouses und Business Intelligence Systemen. Informatik-Spektrum, S. 3-14.
- Inmon, W. (2000). ODS Types. (I. M. Magazine, Herausgeber) Abgerufen am 07. 12 2011 von <http://www.information-management.com/issues/20000101/1749-1.html>
- Kemper, H.-G., Baars, H., & Mehanna, W. (2010). Business Intelligence - Grundlagen und praktische Anwendungen: Eine Einführung in die IT-basierte Managementunterstützung. Wiesbaden: Vieweg+Teubner.
- Keppel, B., Müllenbach, S., & Wölkhammer, M. (2001). Vorgehensmodelle im Bereich Data Warehouse: Das Evolutionary Data Warehouse Engineering (EDE). In R. Schütte, T. Rotthowe, & R. Holten, Data Warehouse Managementhandbuch - Konzepte, Software, Erfahrungen (S. 81-106). Berlin u.a.: Springer.
- Lusti, M. (2002). Data Warehousing und Data Mining - Eine Einführung in entscheidungsunterstützende Systeme. Berlin u.a.: Springer.
- Melchert, F. (2004). Metadatenmanagement im Data Warehousing - Ergebnisse einer empirischen Studie. St. Gallen: Universität St. Gallen - Hochschule für Wirtschafts-, Recht- und Sozialwissenschaften (HSG).
- Moore, A., & Wall, J. (01. 11 2000). The Data Administration Newsletter. Abgerufen am 05. 01 2012 von <http://www.tdan.com/view-articles/4883>
- Muksch, H. (2006). Das Data Warehouse als Datenbasis analytischer Informationssysteme - Archi-

- tektur und Komponenten. In P. Chamoni, & P. Gluchowski, Analytische Informationssysteme - Business Intelligence-Technologien und -Anwendungen (S. 129-142). Berlin u.a.: Springer.
- Navrade, F. (2008). Strategische Planung mit Data-Warehouse-Systemen. Wiesbaden: Gabler Verlag.
- Petersohn, H. (2005). Data Mining Verfahren, Prozesse, Anwendungsarchitektur. München: Oldenbourg Verlag.
- Pohl, K. (2007). Requirements Engineering - Grundlagen, Prinzipien, Techniken. Heidelberg: dpunkt.
- Ponniah, P. (2001). Data Warehousing Fundamentals - A Comprehensive Guide for IT Professionals. New York u.a.: Wiley.
- Portal, D. B. (o.J.). Fakten zu Business Rules. Abgerufen am 23. 11 2011 von <http://www.brportal.org/German/Einfuehrung/Fakten.htm>
- Redman, T. C. (1995). Improve Data Quality for Competitive Advantage. Sloan Management Review, Vol. 36, No. 2, S. 99-107.
- Schacher, M., & Grässle, P. (2006). Agile Unternehmen durch Business Rules. Berlin u.a.: Springer.
- Scheer, A., & Werth, D. (2006). Geschäftsprozessmanagement für das Unternehmen von morgen. In D. Karagiannis, & B. Rieger, Herausforderungen in der Wirtschaftsinformatik - Festschrift für Hermann Krallmann (S. 49-64). Berlin: Springer.
- Schelp, J. (2000). Modellierung mehrdimensionaler Datenstrukturen analyseorientierter Informationssysteme. Wiesbaden: Deutscher Universitätsverlag.
- Schinzer, H. (2001). Marktüberblick Data Warehouse-Werkzeuge. In R. Schütte, T. Rotthowe, & R. Holten, Data Warehouse Managementhandbuch - Konzepte, Software, Erfahrungen (S. 121-142). Berlin u.a.: Springer.
- Schmidt-Volkmar, P. (2008). Betriebswirtschaftliche Analyse auf operationalen Daten. Wiesbaden: Gabler.
- Sen, A. (37 2004). Metadata management: past, present and future. Decision Support Systems, S. 151-173.
- Sinz, E., Böhnlein, M., Plaha, M., & Ulbirsch-vom Ende, A. (2001). Architekturkonzept eines verteilten Data-Warehouse-Systems für das Hochschulwesen. In H. Buhl, A. Huther, & B. Reitwiesner, Information Age Economy - 5. Internationale Tagung Wirtschaftsinformatik 2001 (S. 57-72). Heidelberg: Springer.
- Soeffky, M. (11 2001). Qualität von Unternehmensdaten. IS Report, S. 12-18.
- Stahlknecht, P., & Hasenkamp, U. (2005). Einführung in die Wirtschaftsinformatik. Berlin: Springer.
- Stein, B. (2001). Konzeption einer Data Warehouse-gestützten Balanced Scorecard in der der öf-

- fentlichen Verwaltung. In W. Behme, & H. Muksch, Data Warehouse-gestützte Anwendungen - Theorie und Praxiserfahrungen in verschiedenen Branchen (S. 85-115). Wiesbaden: Gabler.
- Strohmeier, S. (2008). Informationssysteme im Personalmanagement. Wiesbaden: Vieweg+Teubner.
- Totok, A. (2000). Modellierung von OLAP- und Data-Warehouse-Systemen. Wiesbaden: Gabler Verlag.
- Treiblmaier, H. (1. 50 2010). Datenqualität und Validität bei Online-Befragungen. der markt, S. 3-18.
- Vasile, G., & Mirela, O. (4. 17 2008). Data Quality in Business Intelligence Applications. Annals of University of Oradea, Economic Science Series, S. 1364-1368.
- Würthele, V. G. (2003). Datenqualitätsmetrik für Informationsprozesse. Dissertation: ETH Zürich.
- Zeh, T. (18 2003). Data Warehousing als Organisationskonzept des Datenmanagements - Eine kritische Betrachtung der Data-Warehouse-Definition von Inmon. Informatik Forsch. Entw., S. 32-38.
- Zwirner, M. (2008). Datenbereinigung zielgerichtet eingesetzt zur permanenten Qualitätssteigerung. In Daten und Informationsqualität - Auf dem Weg zur Information Excellence (S. 102-122). Wiesbaden: Vieweg + Teubner Verlag.

Lösungen zu den Übungsaufgaben

1. Erläutern Sie die verschiedenen Typen von Business Rules!

Es gibt drei verschiedene Typen von Business Rules. Diese sind Ableitungsregeln, Einschränkungen und Prozessregeln. Ableitungsregeln zeichnen sich dadurch aus, dass die Regeln dadurch entstehen, indem auf bereits bestehende Regeln oder Informationen zurückgegriffen wird und sich dadurch neue Business Rules ableiten lassen. Einschränkungen können in der Form von Geboten oder Verboten vorliegen, die zu jeder Zeit gelten. Prozessregeln werden immer in der Form „wenn xyz dann abc“ formuliert. Sie drücken somit aus, dass ein Sachverhalt oder eine Aktivität eine andere Aktion auslöst.

2. Erläutern Sie, weshalb fachliche Metadaten häufig auch als unstrukturierte Metadaten bezeichnet werden!

Fachliche Metadaten können im Gegensatz zu technischen Metadaten häufig nur unstrukturiert erhoben werden. Mitarbeiter der Fachabteilungen sammeln durch die Anwendung und Erfahrung implizites Wissen, das in explizites Wissen transformiert werden muss. Dies kann durch Interviews oder Beobachtungen erfolgen. Technische Metadaten dagegen werden strukturiert erhoben bzw. entstehen bei der Entwicklung, dem Betrieb sowie der Wartung des Datenbanksystems.

3. Erläutern Sie die Bedeutung von Metadaten anhand des Beispiels der Datumsangabe 10/12/99!

Die Interpretation dieses Datums ist für den Endbenutzer nicht eindeutig. So könnte dieses Datum nach der britischen Schreibweise interpretiert werden als 12. Oktober 1999 oder aber auch als amerikanische Schreibweise als 10. Dezember 1999. Somit wird die Bedeutung der Metadaten ersichtlich. Metadaten legen die Struktur des Datenobjekts fest. Es werden also Angaben darüber in den Metadaten erfasst, ob die Interpretation und Erfassung des Datums nach der englischen oder britischen Schreibweise erfolgen soll.

4. Grenzen Sie dispositive und operative Daten voneinander ab!

Dispositive und operative Daten unterscheiden sich grundlegend voneinander. Folgende Tabelle gibt einen Überblick über die Eigenschaften von dispositiven und operativen Daten.

Eigenschaft	Dispositive Daten	Operative Daten
Ziel	Entscheidungsunterstützung	Unterstützung des Tagesgeschäfts
Zustand	Kontrollierte Redundanzen und konsistent	Häufig redundant und inkonsistent
Modellierung	Sachgebiets- und themenorientiert	Funktions-/transaktionsorientiert
Zeitbezug	Historienbetrachtung über den Zeitverlauf	Aktuell, zeitpunktbezogen
Ausrichtung	Meist verdichtet, transformiert	Detaillierte, granulare Geschäftsvorfalldaten

5. Erläutern Sie die zentralen Eigenschaften eines DWH nach Inmon!

Nach Inmon weist ein DWH die Eigenschaften themenorientiert, integriert, zeitraumbezogen und nicht-volatil auf. Themenorientiert bedeutet, im Gegensatz zu funktions-/transaktionsorientiert, dass die Daten nach Themen wie z. B. Kunden, Produkten oder Mitarbeiter gehalten werden. Die Themen können je nach Unternehmen variieren. Integriert bedeutet, dass die Daten, obwohl sie aus verschiedenen Applikation stammen und somit in unterschiedlicher Form gespeichert werden, in einem DWH so angepasst werden, dass letztlich integrierte Daten vorliegen. Zeitraumbezogen impliziert, dass Daten über einen Zeitverlauf betrachtet werden, sodass die historische Entwicklung berücksichtigt werden kann. Die Eigenschaft nicht-volatil besagt, dass Daten nicht vergänglich sind, sondern dauerhaft vorgehalten werden. Hierdurch ergibt sich auch die vorherige Eigenschaft der zeitraumbezogenen Daten.

6. Nennen und erläutern Sie die drei Phasen im ETL-Prozess!

Der ETL-Prozess besteht aus den Phasen Extraktion, Transformation und Laden. Bei der Extraktion werden die Daten von der Datenquelle in den Arbeitsbereich übertragen. Dabei sollte die Beschaffenheit sowie die Relevanz der Daten berücksichtigt werden. Die Extraktion sollte nach Möglichkeit automatisiert erfolgen. Neben der Entscheidung, welche Daten extrahiert werden sollen, muss auch darüber entschieden werden, wie häufig die Extraktion durchgeführt werden soll. In der zweiten Phase erfolgt die Transformation der Daten. Dabei werden die Daten so angepasst, dass sie im nächsten Schritt in das DWH geladen werden können. Häufig werden Daten in dieser Phase standardisiert oder fehlerhafte Daten werden korrigiert, bereinigt oder gelöscht. In der Ladephase werden die Daten in das DWH übertragen. Dabei werden zwei Ladephasen unterschieden: beim Initial load werden die Daten einmalig vom Arbeitsbereich in das DWH geladen, beim refresh werden die Daten in regelmäßigen Abständen aus der Datenbank in das DWH geladen.

7. Welche verschiedenen Ebenen lassen sich in einem DWH-System unterscheiden? Erläutern Sie diese kurz!

In einem DWH-System gibt es fünf verschiedene Ebenen. Diese sind die Ebene der operativen Systeme, die Datenerfassungsebene, die Datenhaltungsebene, die Datenbereitstellungsebene sowie die Präsentationsebene. In der Ebene der operativen Systeme befinden sich die unterschiedlichen Datenquellen, aus denen die Daten stammen können. Diese Ebene ist eigentlich dem DWH-System vorgelagert. In der Datenerfassungsebene werden die Daten physisch in den Bereich des DWH-Systems gebracht. Zudem erfolgt hier die Bereinigung, Harmonisierung und Zusammenführung der Daten. In der Datenhaltungsebene werden die Daten durch die ETL-Komponente des DWH zugeführt. In der Datenbereitstellungsebene findet die zweckmäßige Aufbereitung der Informationen, die für den Entscheidungsträger relevant sind, statt. Auf der Präsentationsebene erfolgt die adäquate Aufbereitung und insbesondere auch Präsentation der Daten. Zudem müssen Erfolgsgrößen kritisch überwacht werden, sodass bei Überschreitung kritischer Wertgrenzen eine Benachrichtigung an den Entscheidungsträger gesendet wird.

8. Grenzen Sie Data Marts und DWHs voneinander ab!

Der **Adressat** eines Data Marts ist immer nur ein Teil eines Unternehmens, z. B. eine Abteilung, wohingegen beim DWH das ganze Unternehmen als Adressat gesehen werden kann. Daraus ergibt sich, dass sich Data Marts und DWHs auch hinsichtlich der **Anzahl** unterscheiden. So existiert in einem Unternehmen lediglich ein DWH, wohingegen viele Data Marts (z. B. so viele, wie es Abteilungen in einem Unternehmen gibt) existieren. Ein weiterer Unterschied ist der **Detaillierungsgrad** der Daten. In einem Data Mart sind die Daten zumeist höher aggregiert als in einem DWH. Die **Datenmenge** ist in einem Data Mart aufgrund der hohen Anzahl verschiedener Data Marts eher niedrig, beim DWH dagegen hoch. **Externe Datenquellen** beeinflussen Data Marts nicht, bei DWHs werden externe Datenquellen integriert. Ein weiterer Unterschied ist, dass bei Data Marts Endanwender direkt darauf **zugreifen** können, bei DWHs ist dies meistens nicht erlaubt. Aufgrund der hohen Anzahl an Data Marts sind die **Modellierungskonventionen** meistens sehr heterogen. Bei einem DWH sind sie einheitlich. Der **Freiheitsgrad** der Analysen ist bei Data Marts eher begrenzt, da Abteilungen in der Regel nicht über ihre Abteilungen hinausblicken, bei einem DWH dagegen flexibel. Der letzte Unterschied liegt im **betriebswirtschaftlichen Ziel**. Data Marts sollen Entscheider einer Abteilung und deren Anforderungen an die Analyse effizient unterstützen. DWHs hingegen sollen auf Ebene des Managements Unterstützung leisten.

9. Erläutern Sie die Eigenschaften online analytical und processing im Rahmen von OLAP!

Online bedeutet, dass Anwender direkt auf den zentralen Datenbestand zugreifen können, um Daten zu betrachten oder zu manipulieren. Die Eigenschaft analytical steht dafür, dass unterschiedliche Sichten für die Entscheidungsträger von Bedeutung sind und nicht, wie beim OLTP die verschiedenen Geschäftsvorfälle. Processing steht für die Eigenschaft, dass schnelle Berechnungen und Manipulationen durch den Anwender durchgeführt werden können

10. Was besagt das Prinzip FASMI im Rahmen von OLAP?

FASMI steht für fast analysis of shared multidimensional information. Daraus ergeben sich fünf Eigenschaften, die OLAP zugeordnet werden können. So sollen Anfragen von Anwendern **schnell**, innerhalb von maximal fünf Sekunden, beantwortet werden. Zudem soll OLAP eine **benutzerfreundliche Analysemöglichkeit** sein. So sollen Anwender einfache Funktionen für ihre Analysen nutzen können. **Shared** bedeutet, dass Anwender gleichzeitig auf ein und dieselben Daten zugreifen können. **Multidimensionalität** der Daten besagt, dass ein Anwender bei der Nutzung von OLAP mehrere Dimensionen entsprechend seinen Bedürfnissen miteinander kombinieren und zu Analysen verwenden kann.

11. Erläutern Sie die Funktionalität „Pivotierung“ im Rahmen von OLAP!

Bei der Pivotierung wird der OLAP-Würfel um seine eigene Achse gedreht. Dabei kann die Drehung entweder um die horizontale oder um die vertikale Achse erfolgen. Das Ziel der Pivotierung ist es, die betrachteten Dimensionen gegeneinander auszutauschen, um so eine weitere Analyse durchzuführen.

Diese Seite bleibt aus technischen Gründen frei!

2001332
(04/26)

32711-03-S#1



Alle Rechte vorbehalten
© 2026 FernUniversität in Hagen
Fakultät für Wirtschaftswissenschaft